

基于超限学习机的半参数自适应控制研究

2017 年 12 月

中图分类号 TQ028.1

UDC分类号: 540

基于超限学习机的半参数自适应控制研究

作者姓名	***
学院名称	自动化学院
指导教师	** 教授
答辩委员会主席	** 教授
申请学位	工学硕士
学科专业	控制科学与工程
学位授予单位	北京理工大学
论文答辩日期	2017 年 12 月

Semi-parametric Adaptive Control Based on Extreme Learning Machine

Candidate Name:	***
School or Department:	School of Automation
Faculty Mentor:	Prof. **
Chair, Thesis Committee:	Prof. **
Degree Applied:	Master
Major:	Control Science and Engineering
Degree by:	Beijing Insititute of Technology
The Data of Defence:	12, 2017

基于超限学习机的半参数自适应控制研究

北京理工大学

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下进行的研究工作获得的研究成果。尽我所知，文中除特别标注和致谢的地方外，学位论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京理工大学或其它教育机构的学位或证书所使用过的材料。与我一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此申明。

作者签名：_____ 签字日期：_____

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：① 学校有权保管、并向有关部门送交学位论文的原件与复印件；② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；③ 学校可允许学位论文被查阅或借阅；④ 学校可以学术交流为目的，复制赠送和交换学位论文；⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

作者签名：_____ 导师签名：_____

签字日期：_____ 签字日期：_____

摘要

传统方法对解决同时存在参数和非参数不确定性的系统存在设计、解释和实现困难等局限性，特别是在现代数字化离散时间控制系统中。半参数自适应控制给出了一种新的理论框架，解决两种不确定性同时出现的系统。而现有的半参数自适应估计与控制还存在准确性和实时性都不佳等问题，需要进一步完善。本文系统性论述了半参数建模、估计与控制算法的设计思路，将计算几何、超限学习机、数据驱动等方法引入到控制器设计中，并应用到机器人与电机控制中，对解决实际问题进行了初步尝试。

首先，研究了一般系统中广泛存在的不确定性特点，对自校正调节器、模型参考自适应、鲁棒控制、无模型自适应等经典控制方法进行了对比分析；在阐述反馈机制能力极限问题的基础上，介绍了一种半参数建模与分析方法，突出了参数不确定性和非参数不确定性的各自特征；对常用的先验信息进行了数学描述，从而引出信息浓缩估计算法，用于解决系统参数部分不确定性的估计。

然后，描述了二维参数情形下信息浓缩估计算法的主要步骤和基本问题，对信息浓缩变换中直线和多边形的几何关系进行了详细地分析，同时设计了信息浓缩变换的算法流程图；在实际的被控对象中仿真前面设计的信息浓缩估计算法，讨论了信息浓缩估计的计算复杂度优化问题，总结了信息浓缩估计的主要优缺点。

接着，给出了半参数自适应轨迹跟踪问题的数学描述，并分析了半参数模型的自适应估计和控制问题；分析了超限学习机的算法特点，并利用合适的超限学习机变体算法设计了非参数部分的估计算法；在信息浓缩和超限学习机的自适应估计基础上，设计了针对半参数系统轨迹跟踪问题的自适应控制器，用仿真实例对比测试和验证控制算法的性能。

最后，分析了机器人轨迹跟踪和伺服电机运动控制中多种不确定性存在等控制难点，将基于超限学习机的半参数自适应理论与方法应用到运动控制中，解决机器人运动中电机的控制问题，通过仿真对比实验测试和验证半参数自适应运动控制的性能。在文章的最后归纳总结了本文的主要工作，并指出了本课题的继续研究方向。

关键词： 超限学习机；信息浓缩估计；半参数自适应；运动控制

Abstract

The traditional methods have some limitations such as the designing, interpretation and implementation of the system for simultaneously solving parametric and non-parametric uncertainties, especially in the modern digital discrete-time control system. Semi-parametric adaptive control gives a new theoretical framework to solve the plants with these two kinds of uncertainties. However, the existing semi-parametric adaptive estimation and control still have some problems, such as accuracy and real-time properties, which need to be further improved. This thesis systematically discusses the the designing methods of semi-parametric modeling, estimation and control algorithms, and introduces the concepts of computational geometry, extreme learning machine and data-driven into the design of controllers. In addition, this series of proposed methods has been applied in the robotic manipulator and motor control as initial attempt for practical problems.

First of all, this thesis studies the characteristics of uncertainties existing in the general system and comparatively analyzes the classical control methods such as self-tuning regulator, model reference adaptive, robust control, model-free adaptive and so on. A novel kind of method called semi-parametric modeling and analysis method is introduced, highlighting the respective characteristics of parametric uncertainty and non-parametric uncertainty. The mathematical description of priori information are established for typical systems and thus information concentration estimation algorithm are used to solve the estimation problem of parametric uncertainty part.

Second, the main steps and basic problems of the information concentration estimation algorithm in the case of two-dimensional parameters are described. The geometric relationships between lines and polygons in the information concentration process are analyzed in detail. At the same time, the flow chart of the algorithm of information concentration transformation is designed. The simulation examples of the proposed information concentration estimation algorithm are depicted. The computational complexity optimization of information concentration estimation has been discussed. The main advantages and disadvantages of the information concentration estimation have been summarized.

Third, the mathematical description of semi-parametric adaptive trajectory tracking is

given, and the problem of adaptive estimation and control of semi-parametric model is analyzed. The algorithm characteristics of the extreme learning machine are analyzed. The non-parametric part estimation method based on the appropriate variant algorithm of extreme learning machine has been proposed. According the adaptive estimation of information concentration and extreme learning machine, one kind of adaptive controller is designed for the trajectory tracking problem of semi-parametric systems. The simulation examples are used to compare the performance of testing and verifying control algorithms.

Finally, the control difficulties of robot trajectory tracking and servo motor motion control with multiple uncertainties are analyzed. Semi-parametric adaptive estimation and control based on extreme learning machine are applied to solve the motor control in robot motion problem. The performance of proposed adaptive motion control have been tested and verified through simulation comparison experiment. In the end, the main contents of this thesis are summarized and the future research orientation of this topic are discussed.

Key Words: extreme learning machine; information concentration estimation; semi-parametric adaptive; motion control

目录

摘要	I
Abstract	II
第 1 章 绪论	1
1.1 本论文研究的目的和意义	1
1.2 国内外研究现状及发展趋势	2
1.2.1 自适应控制	3
1.2.2 非线性估计与神经网络	6
1.2.3 超限学习机与控制	8
1.3 本文主要研究内容	8
第 2 章 半参数系统与信息浓缩估计	10
2.1 反馈机制能力极限的探索	10
2.2 半参数系统	12
2.2.1 模型描述	12
2.2.2 先验知识举例	13
2.3 信息浓缩估计	15
2.3.1 提出背景	15
2.3.2 主要思想	16
2.3.3 典型实现	18
2.4 本章总结	22
第 3 章 二维参数的信息浓缩估计算法	23
3.1 问题描述	23
3.2 几何关系分析	24
3.3 算法实现	27

3.4	仿真实例	30
3.5	优化问题	31
3.6	主要特点	33
3.7	本章总结	34
第 4 章	离散时间半参数自适应控制	35
4.1	问题描述	35
4.2	非参数部分的估计	36
4.2.1	最近邻估计	36
4.2.2	神经网络	38
4.2.3	ELM 及其变体	42
4.2.4	ELM 估计	44
4.3	自适应控制器	47
4.3.1	算法设计	47
4.3.2	稳定性分析	49
4.4	仿真实例	50
4.4.1	仿真环境	50
4.4.2	仿真结果	52
4.5	本章总结	53
第 5 章	半参数自适应运动控制	55
5.1	问题描述	55
5.1.1	机器人控制	55
5.1.2	伺服电机控制	56
5.2	控制器设计	58
5.2.1	半参数建模	58
5.2.2	自适应估计	60
5.2.3	控制器设计	61

5.3 仿真实例	62
5.4 本章总结	66
结论	67
参考文献	69
附录 A ***	72
攻读学位期间发表论文与研究成果清单	73
致谢	74
作者简介	75

第 1 章 绪论

1.1 本论文研究的目的和意义

自动控制理论的进步和发展意味着动态系统的性能更优，意味着生产力的提高和自动化程度的提高等，因此自动控制在工程和科学领域一直都起着至关重要的作用。自动控制的基本思想可以追溯到公元前 300 年左右^[1]，其理论的初步形成源于在二十世纪中叶奈奎斯特、伯德、维纳等人建立的经典控制理论，主要运用频率法和根轨迹法等分析工具；1960 年左右，Kalman 等人提出的状态空间方法与概念标示着现代控制理论与方法的萌芽和诞生。而后，自动控制系统的运行环境越来越复杂，人们对系统控制的目标越来越多，要求也越来越苛刻。随着科学技术的发展和应用需求的不断催生，加上众多学者的不断努力，基于状态空间、传递函数等反馈理论基础和实践过程，现代控制理论迅速兴起。近年来，不论是在现代工业领域，还是在国防科技领域，现代控制理论都发挥着举足轻重的作用。线性系统理论、系统辨识理论、最优控制理论、自适应控制理论和鲁棒控制理论等重要分支的蓬勃发展，促进了自动控制在机器人伺服系统、工业过程、航空航天、人口与经济控制等领域的应用。

在经典控制理论和现代控制理论中，通常假设被控对象是线性系统并且模型的参数是精确已知的，然后以此为前提设计控制律。典型的控制方法^[2, 3]就是比例-积分-微分（PID）控制、极点配置^[4]、线性二次型调节器等。其中针对单变量的 PID 反馈控制算法应用十分广泛，到目前为止，工业过程大部分也都采用 PID 控制或者其改进算法。实际系统从本质上来说都是非线性的，而非线性系统的表现形式丰富多彩，比如饱和、时滞、间隙、死区等；对这些的复杂非线性系统，目前没有很好的系统辨识方法和实际测量工具能够给出系统精确的建模结果，对系统认知的有限性和对系统模型不精确描述，造成系统普遍存在一定的不确定性；许多系统例如机器人、飞行器等运动控制系统都是强耦合的，增加了系统的不确定性。系统的非线性（nonlinearity）和不确定性（uncertainty）给分析和设计控制律带来了极大的挑战。一方面，由于系统工作环境和时间累积的影响，系统实际模型的参数和标称模型的参数总会存在不确定的误差，系统的负载和惯量也会在长时间运行之后发生变化，这些因素都导致了系统参数的不确定性，如果不加以处理可能降低系统的性能。另一方面，系统中可能存在的未建模动态、执行器的非线性特性等，也会增大系统的不稳定性和整体性能，如摩

摩擦非线性会引起伺服系统在低速运转下的不平稳，出现时滞现象；而输入间隙、死区则容易导致系统出现抖震和极限环。因此作为影响系统控制性能的重要因素，与系统不确定性特别是非线性系统的不确定性相关理论研究和实际运用一直备受关注。

随着计算机技术、网络技术的飞速发展，越来越多的控制系统采用数字微处理器作为控制器，特别是机器人伺服系统、航空航天控制系统等运动控制领域。数字化和网络化是现代伺服电机和飞行控制器等的发展趋势。机器人和飞行器等本体作为被控对象，从本质上来说都是连续时间系统，而给这些被控对象施加的都是离散控制信号，只是采样时间很短，通常在毫秒级别。为了简化，在给这些系统设计控制律的时候，常常借助于连续时间控制理论去设计，然后直接施加离散时间控制信号。这样的手段在使用过程中一般不会出现问題，但是存在着隐患，因为系统离散化后特性常常发生变化，也就是输入输出关系发生了改变，特别是非线性和不确定性等特性经过离散化变得更加不可预测。例如，摩擦、死区等非光滑非线性经过离散化之后，更加难以用数学模型精确描述或近似，增加了系统的不确定性。如果不加考虑，可能会使得系统不稳定。因此，从离散时间角度研究实际系统的控制问题更加符合真实条件。

本文将上述的非线性、不确定性和离散化导致的未知因素统一归纳为参数不确定性（parametric uncertainty）和非参数不确定性（non-parametric uncertainty）。随着控制理论不断发展，对非线性系统的不确定性的处理方法也越来越多，如鲁棒控制、自适应控制等。在这些方法中，自适应控制基于其完善的理论基础和良好的鲁棒性能，在系统不确定性的相关研究中起着极其重要的作用。自适应控制在线性系统中的应用相对来说已经比较成熟，基于连续时间对象的自适应控制算法也层出不穷。然而针对同时具有参数不确定性和非参数不确定性的离散时间自适应控制相关研究还处于探索阶段。本文将借鉴一些其他领域的思想，如机器学习、数据驱动、先验信息关联、计算几何等，解决同时存在这两种不确定性的系统的控制问题，这一方向的研究具有相当大的理论意义和实用价值。

1.2 国内外研究现状及发展趋势

下面介绍本课题涉及到的理论和方法在国内外的研究现状和主要发展趋势。

1.2.1 自适应控制

一般认为,自适应控制的相关理论和技术起源于二十世纪五十年代解决不同飞行高度飞行器的控制器设计问题。自适应控制是指在指在被控对象的参数未知或者时变的情形下,在常规反馈控制器中引入自适应算法,动态地对控制方案进行调节,以抵消被控对象的模型时变或受到较大干扰的影响。线性系统的自适应控制方法已经比较成熟,在解决线性被控对象在参数未知和时变情形下取得了比较满意的控制效果。自适应控制的核心思想在于对系统不确定性进行估计、辨识和学习,同时设计出稳定的控制律,这使得控制器能满足系统的实际情况。辨识与控制的具体设计是实现自适应估计与控制哲学的关键步骤。模型参考自适应控制(Model Reference Adaptive Control, MRAC)和自校正控制(Self-tuning Control, STC)是解决线性系统的两类典型自适应控制方法。除了这两种写入教科书的经典自适应控制方法外,经过数十年的发展,针对不同特点的系统,形成了许多自适应方法,如特征模型全系数自适应控制、集值系统自适应控制、L1-自适应控制、无模型自适应控制等;另外,自适应控制思想与其他方法结合,还涌现了一系列自适应控制方法,如和PID结合形成自适应PID整定,与模糊数学结合形成模糊自适应控制^[5]等。

除了自适应控制,在解决系统的不确定性问题时,鲁棒控制也是一种比较常用的方法。当系统存在一定程度的参数不确定性和未建模动态时,鲁棒控制方法可以使得闭环系统仍能保持稳定,并保持一定的动态性能^[6]。一般来说,鲁棒控制器的设计和最终效果都依赖于对系统不确定性程度的先验假设。为了使系统稳定,常常假设系统的不确定性在较小的范围内,并且鲁棒控制器设计过程中某些项的对消或者抑制等也严格利用了系统的假设结构和精确的先验知识,这样导致鲁棒控制不能解决系统存在较大不确定性的情形。相对于鲁棒控制,自适应控制由于在反馈回路中嵌入了在线学习机制,因此能够对付比较大的系统不确定性。

针对非线性特性或者非参数不确定性的辨识方法常常是设计出性能满意的自适应控制律的难点,特别是对于现代数字化控制器,在被控对象的数据经过离散采样化之后系统对应的结构和参数都存在较大不确定性。虽然经典的控制理论是从连续时间系统的研究出发,并且现代控制理论很多也是基于连续时间对象考虑的,但是在许多实际应用中也取得了比较好的控制效果。但是,基于模拟量的连续控制器由于扩展性和可重构性差,且设计复杂的控制规律时十分复杂,随着计算机技术的发展逐渐被历史淘汰。相反,数字化和离散化控制器越来越被广泛应用。实际的被控对象是离散时

间系统，这样从连续时间角度设计的控制器嵌入到实际过程中形成闭环系统后，与理论分析有较大偏差，这必然会限制实际的控制性能的提高。

经典的模型参考自适应控制主要针对连续时间系统建立。自校正控制从一开始就是针对离散时间系统而建立的自适应控制规律，即可考虑如下被控对象

$$y_{k+1} = \theta^T \cdot \phi_k + \epsilon_{k+1} \quad (1.1)$$

其中, u_k, y_k 在 k 时刻的系统输入和输出; $\phi_k = [y_k, y_{k-1}, \dots, y_{k-p+1}, u_k, u_{k-1}, \dots, u_{k-q}]^T$; p 和 q 分别是系统输出变量 y_k 和输入变量 u_k 的阶数; θ 是待估计的参数; ϵ_k 是干扰。对于(1.1)这样的被控对象，使用最小二乘算法（Recursive Least Squares, LS）去辨识未知参数 θ ，或者递推最小二乘算法（Recursive Least Squares, RLS）^[7] 及其诸多变体（如加入遗忘因子的 RLS^[8]）。在解决实际问题时，自校正控制采用参数辨识和必然等价原理设计自适应控制律，这是一种比较容易理解的思路。最小二乘算法主要针对线性系统设计，因而导致经典的基于 LS 的自校正调节器^[9] 难以对付强非线性的被控对象，相关对比实验也表明了从线性系统角度出发设计的自适应控制在碰到存在具有强非线性不确定性系统时的捉襟见肘^[10]。这常常表现为系统的跟随性能满足不了要求，系统的实际输出与期望值存在较大偏差，或者系统难以对付较大的非线性干扰。不过，传统自校正控制算法设计中的必然等价原理对后续的自适应控制器的设计有很好的指导意义。

上述讨论的模型(1.1)常常被称为带外部输入的自回归模型（auto-regression model with extra input, ARX）^[11]，其中的未知参数向量 θ 刻画了系统的不确定性，但只是考虑到了参数不确定性。另一种模型被称为 Nonlinear ARX（NARX）模型，其单输入单输出情形的方程为

$$y_{k+1} = f(y_k, y_{k-1}, \dots, y_{k+1-p}, u_k, u_{k-1}, \dots, u_{k+1-q}) + \epsilon_{k+1} \quad (1.2)$$

其中, $f(\cdot)$ 代表某个未知的非线性函数。方程(1.2)从非线性的角度刻画了系统的不确定性，将系统当作一个几乎可以说是黑箱的模型，几乎完全不受限于系统的具体结构和参数，直接建立系统输入输出的对应关系。除了随机干扰之外，(1.2)整个系统的不确定性主要体现在未知函数关系 $f(\cdot)$ 上，显然其囊括了线性过程(1.1)，似乎可以当作一种通用的模型，从而解决之前的问题。然而，要解决好系统(1.2)的自适应控制问题

十分困难，有赖于较好的非线性辨识方法和基于辨识结果设计出合适的控制输入 u_k 的表达式，这就涉及到非线性离散时间自适应控制，这种非线性控制方法^[12-14]也都大多针对满足一定简化条件的非线性模型或者某一特定的被控对象进行研究，针对不同的结构采用不同的方法，设计和分析都比较复杂，且通用性较差。

解决具有较大不确定性的非线性系统时，难以找到合适的参考模型与之对应以及难以满足匹配条件，就难以实施模型参考自适应控制方法。从必然等价原理出发实施自适应控制需要解决非线性系统的辨识（identification）与估计（estimate）问题。辨识高阶复杂的受控对象模型依赖于很好的辨识算法，并且，高阶复杂的系统辨识容易导致高阶复杂的控制器，而高阶复杂的控制器会给控制技术的具体实施、诊断维护、成本控制等带来一系列困难。有一些基于数据驱动的自适应控制避开了这个问题，例如，无模型自适应控制^[15]依据系统的输入输出数据设计控制律，充分利用了数据驱动的思想，不过其算法依赖于动态线性化数据模型的准确性，其假设模型具有局限性。综上所述，在伺服电机、机器人、飞行器等具有强非线性、强耦合的离散时间被控系统中，未知参数、非线性动态特性、未知干扰和控制器离散时间化带来的不确定性等这些问题并得到没有很好的解决。

设计上述被控对象的自适应控制器的难点在于如何解决同时存在被控系统的参数不确定性和非参数不确定性^[16]。运动控制系统在高速或者超低速等情况下往往具有很大的不确定性，需要自适应反馈，诸如此类。近年来，郭雷院士等学者^[17]指出自适应反馈机制是存在极限的。受自适应反馈机制的最大能力和局限这一研究方向的启发，马宏宾等学者^[10]引入基于集合的辨识方法和数据驱动的思想，归纳出了一种等价模型，即半参数系统（semi-parametric system）用来刻画大部分非线性离散时间对象，由此提出了半参数自适应控制这一研究方向。相比于前面提到的常见自适应控制算法，半参数自适应控制出发点具有独特性，和常见的自适应控制算法的详细比较见表(1.1)。半参数自适应控制这一研究方向结合了先验信息和数据驱动的思想，设计思路不依赖于具体的被控对象，是一种比较新颖的思路。目前半参数自适应控制中的非线性部分辨识主要考虑采用的是最近邻估计（nearest-neighbor estimate），这种方法未必最优，可以引入其他非线性辨识方法作进一步的优化和扩展。半参数自适应控制目前正处于探索期，还有待于深入和推广。

表 1.1 常见自适应控制算法比较

算法名称	主要时间特性	适用对象	系统不确定性类别
模型参考自适应控制	连续时间	线性系统	参数
自校正调节器	离散时间	线性系统	参数
无模型自适应控制	离散时间	非线性系统	非参数
半参数自适应控制	离散时间	非线性系统	参数和非参数

1.2.2 非线性估计与神经网络

通常的自适应控制主要处理在控制科学中的参数不确定性，尤其是线性参数不确定性，然而实际系统经常是参数不确定性和非参数不确定性共存，这就给实际的应用带来了很大的困难。为了实现含有较大非线性特性的不确定被控对象的控制，常用的做法是利用系统的输入输出数据去估计系统的非参数不确定性，为设计出满足性能要求的控制律提供依据。从数学上看，自适应控制中的辨识与估计类似于机器学习(machine learning, ML)^[18]，两者的交叉点在于都是通过数据修正输入输出映射关系这一过程来改善系统的性能。基于数据驱动的机器学习方法以客观存在的事物为对象，研究数据的客观规律，实现数据的分类和预测。机器学习是人工智能的核心^[19]，是使计算机具有智能的根本途径。自从上世纪中叶以来，机器学习在理论研究、算法设计和工程应用等方面都取得了飞速发展。

人工神经网络(Artificial Neural Network, ANN)是机器学习的一个庞大的分支，通常用于解决分类和回归问题。20 世纪感知机和神经网络概念被提出以来，有关神经网络(Neural Network, NN)的研究走过的是一条波浪式推进、起伏跌宕的发展道路，其在模式识别、不同的领域应用已经十分广泛 [23]。神经网络的基本结构示意图如图1.1所示，主要包括 1 个输入层、0 个或多个隐含层和一个输出层。

一般认为，网络结构、激活函数(activation function)和学习算法是神经网络的三大要素。神经网络的分类主要依据这三要素，而学习能力是其主要特点^[20]。学习过程是根据训练数据，通过不断修正神经元之间的连接权值及每个神经元的阈值来实现的。它对非线性系统和难以直接建模的系统具有良好的效果。人工神经网络的模型按照信息的传递方向，通常可以分为前馈型神经网络和反馈型神经网络等。在实际的控制系统应用中，由于反馈神经网络运算十分耗时间且设计复杂，因此对于在线动力学辨识和实时控制系统应用较少。前馈结构在解决高度非线性和严重不确定性系统的建模与控制方面具有很大潜力。将神经网络引入控制系统是重要的突破^[21]，陆续出现了




图 1.1 多层前馈神经网络的结构示意图（含 2 个隐含层）

神经网络逆控制、神经广义预测控制、自适应神经输出反馈控制和模糊神经网络控制等方法。

对于控制界，神经网络的吸引力在于其强大的非线性建模与辨识能力，主要体现在以下几个方面：

1. 逼近能力。神经网络能够逼近任何一个非线性函数，因而能以非常高的精度逼近具有复杂动态特性的非线性系统；
2. 容错能力。一般神经网络都存在大量神经元，类似与动物的神经中枢系统，网络中少数神经元的连接损坏几乎不会影响系统的整体功能，因而表现出很强的鲁棒性和容错性；
3. 并行计算。同一层神经元的更新计算几乎可以同步进行，因而容易部署成并行分布处理的结构，这大大提高了实时性。

不过，神经网络的巨大优势，也难以掩盖其在解决实际控制领域应用时存在的诸多问题。例如，尽管研究出了很多神经控制算法，但绝大多数难以进行有效的闭环系统稳定性分析；神经网络的训练依赖于大量数据，而实际控制系统在很多情况下只能提供小样本量的数据，针对被控对象特性在不断变化的情形，一些传统神经控制就难以满足性能要求；快速在线学习是实时控制算法的关键，而目前大部分神经网络采用基于梯度的学习算法（如误差反向传播，**Back Propagation**，简称 **BP**），计算量十分耗时。综合这几方面的因素，研究和开发新型神经网络，以及相应的实时学习算法，并将其用于控制系统中，已经成为是基于神经网络的自适应算法研究的重要方向。

1.2.3 超限学习机与控制

如前所述，目前的神经网络结构和学习算法难以满足控制系统的实时性、准确性等要求。传统的神经网络需要人为设置大量的网络参数；在网络训练时主要采用 BP 算法，需要耗费很长的时间多次迭代才能修正权值和隐元的偏置^[22]；由于使用梯度下降有陷入局部极小的缺陷，而未到达全局最小。一些研究学者也开始研究基于神经网络的实时辨识与控制算法^[23]，但针对的是特定的问题，难以做到通用性。

2004 年，黄广斌等人针对单隐层前馈神经网络提出了一种新颖^[24, 25]的学习算法，即超限学习机（Extreme Learning Machine, ELM）。超限学习机（最早有时称为极限学习机）的实现过程^[26]主要分为三个阶段，首先初始化输入权重和隐含层神经元的偏置，然后根据输入计算出隐含层的输出，最后由期望的范数解确定输出权重，一般采用欧几里得范数，类似于采用最小二乘法确定。由此看出，基本的超限学习机算法在设置好神经网络隐含层节点个数之后，算法执行过程或者称为网络学习过程中，一般不再需要调整从输入到隐含层的权重以及隐层神经元的偏置，就能直接产生最优解，因此具有学习速度快且泛化性能好的优点。这也是其名字来源的主要原因。相对于传统网络，ELM 在保证更好的泛化性的同时，具有极快的学习速度，且经过改进，可以有效减少传统梯度算法常有的局部极小、学习时间长、性能指标难以保证最优等问题，对于解决许多常见的非线性问题表现出很大的应用潜力。

如上所属，超限学习机是一种通用性很强、快速准确的前馈神经网络学习算法，对于解决手写识别、目标跟踪等领域^[27]的问题取得了丰硕的成果。ELM 具有很好的系统辨识能力，在控制领域也出现了不少应用^[28]，特别是在线序列版本的超限学习机（Online-sequential ELM, OS-ELM）^[29]及其相关变体^[30, 31]，很适合解决具有强非线性的不确定性系统的在线辨识与实时控制问题，如机器人、无人车等运动控制场景^[32, 33]，与自适应控制理论结合，也将形成很多解决问题的思路。

1.3 本文主要研究内容

本文的主要研究对象是同时具有参数不确定性和非参数不确定性的离散时间系统，结合超限学习机对现有的半参数自适应控制进行扩展和改进。主要体现在：(1) 系统地归纳和总结了反馈控制和自适应控制的发展历程和发展趋势，介绍了人工神经网络等重要的非线性建模方法，对现代不确定性被控系统控制中的控制难点进行了提炼；(2)

针对同时具有参数和非参数两种不确定性的系统进行了分析，概括出了一种半参数建模方法，列举了系统常见的先验信息的数学描述；(3) 针对半参数系统介绍了信息浓缩估计思想，并设计了典型情形下的具体实现算法；(4) 分析了经典神经网络学习算法在自适应估计与控制应用中的优缺点，并将超限学习机引入到半参数系统的非参数部分的估计中，设计了基于超限学习机的半参数自适应控制算法；(5) 将基于信息浓缩估计和超限学习机的半参数建模与控制方法应用到机器人运动控制场景中，有效地提高了伺服电机的控制性能，这是半参数控制解决实际应用的初步尝试。

本文的章节安排如下：

第一章是绪论部分，主要阐述了非线性自适应控制的研究背景和意义，总结了经典自适应控制方法的发展历程、特点与方法和存在的问题等，分析了神经网络应用于自适应估计与控制的前景和挑战，并介绍了一些快速有效的非线性辨识方法。

第二章，介绍半参数系统与信息浓缩估计算法。在反馈能力极限等前沿问题基础上，对半参数自适应思想的来源作进一步阐述，正式描述了半参数系统的数学模型，详细介绍了信息浓缩估计的思想和具体实施方法，对原有的一阶半参数自适应估计进行了扩展。

第三章，二维参数的信息浓缩估计算法设计。描述了二维参数情形下，信息浓缩估计算法的主要步骤和基本问题，并对信息浓缩变换中直线和多边形的几何关系进行了详细地分析，同时设计了信息浓缩变换的算法流程，并在数值仿真实例中验证本章设计的信息浓缩估计算法，最后讨论了信息浓缩估计的相关优化问题和主要优缺点。

第四章，离散时间半参数自适应控制。给出了离散时间情形下半参数自适应估计与控制的数学描述，用超限学习机变体算法设计了非参数部分的估计算法，同时针对半参数系统轨迹跟踪问题设计自适应控制器，并用仿真实例对比测试和验证半参数自适应控制算法的性能。

第五章，半参数自适应运动控制。分析了机器人轨迹跟踪和伺服电机运动控制中多种不确定性存在的难点，采用半参数分析方法对单轴伺服电机进行了建模，设计了基于超限学习机的半参数自适应估计与控制算法，并结合具体对象进行了仿真对比测试，从而验证估计与控制的性能。

第 2 章 半参数系统与信息浓缩估计

传统鲁棒控制主要考虑小范围的结构不确定性，传统自适应控制主要考虑系统的参数不确定性，而一般的非线性自适应控制直接考虑非线性模型从而设计复杂的控制器。实际问题中参数不确定性和较大的结构不确定性可同时出现，因此这些方法对于解决非线性不确定性被控对象的离散时间控制问题都存在一定的局限性。所有的被控对象本质上都是非线性的，但是线性控制方法在反馈控制前期发展中起到了很大作用。这不由得让人思考，是否很多非线性对象都存在一个起主要作用的线性模型？按照这个思路，虽然无法精确的已知非线性不确定性系统的离散化模型，但是这些非线性系统可以用一个线性模型（如 ARX 模型）加上一个非线性部分（关于输入输出数据的未知函数）近似，也就是把系统的不确定性分为参数和非参数不确定性。为了解决控制问题，需要先辨识参数部分。这就是本章要介绍的半参数系统和所谓的信息浓缩（information concentration estimate, IC）估计。

2.1 反馈机制能力极限的探索

不管是采用连续时间模型还是离散时间角度设计控制律，实际系统都会存在无法预测的不确定性，如干扰、未建模动态等，这会导致输出就会产生偏差。反馈从一开始就是为了解决这种偏差和不确定性而引入的。传统针对线性时不变系统设计的控制方法属于线性反馈。然而，即便是针对 ARX 模型设计的自校正调节器，自适应控制从本质上说是一种非线性反馈^[34]。当系统存在不确定性时，在设计自适应辨识与控制算法时，是否一定存在一种自适应控制律能够使得系统闭环稳定？这是在设计自适应控制之前首先要回答的问题。然而直到 20 世纪 90 年代末，郭雷院士等学者开始探索反馈机制^[35]，创造性地提出反馈机制的最大能力和局限（the limit to the capability of feedback）这一重要命题，并针对一些基本控制系统的自适应反馈极限进行定量研究，才引起来广泛的关注。

最开始关于反馈机制的研究始于一类基本的不确定非线性系统，即下面的模型

$$y_{k+1} = \theta \phi_k + u_k + \epsilon_{k+1}, \phi_k = O(y_k^b), b > 0 \quad (2.1)$$

其中， u_k 和 y_k 分别是系统在 k 时刻的输入和输出，一般假定 ϵ_k 为高斯白噪声干扰。 θ

是未知参数, b 刻画了系统非线性的增长速率。除了参数不确定性 θ 外, 系统(2.1)的不确定性主要表现为 ϕ_k 的未知性, 即非参数不确定性。经过严格的数学证明, 当 $b \geq 4$ 时, 不存在任何的自适应反馈控制律使得系统(2.1)满足全局稳定。进一步考虑如下的系统:

$$y_{k+1} = f(y_k) + u_k + \epsilon_{k+1}, f(\cdot) \in F(L) \quad (2.2)$$

其中, $f(\cdot)$ 是未知函数, $F(L)$ 代表一类满足 Lipschitz 条件的非线性函数。对于这种非参数不确定性系统, 有如下结论^[36]: 如果 $L < \frac{3}{2} + \sqrt{2}$, 则存在反馈控制律使得系统(2.2)全局稳定; 相反, 若 $L \geq \frac{3}{2} + \sqrt{2}$, 则不存在反馈控制律使得系统(2.2)全局稳定。 $f(\cdot)$ 的绝对值随自变量 y_k 绝对值的增长速率决定了反馈机制能力的上限。

上述这些现象在连续时间非线性系统中至今没有表现出来, 这说明离散时间控制研究的必要性。这些“不可能性”(impossibility)定理表明了, 在离散时间非线性系统的自适应控制中反馈机制存在极限。在随后的研究^[37, 38]中将这一“不可能性”定理推广到了高阶情形, 其中 $f(\cdot)$ 就推广到了多元函数, 同样是满足 Lipschitz 条件。可以这样理解, 如果 $f(\cdot)$ 增长得比较快, 那么就不存在使得系统(2.1)趋于稳定的自适应反馈控制律。分析出反馈机制的上下界并给出数学证明, 确实不是一件容易的事情, 需要极强的数学技巧。这一理论很直观地说明了系统的不确定性的尺寸常常表现为系统未知函数或者参数的变化剧烈程度, 这些结论从控制稳定性和可行性的角度对系统的不确定性给出了一定的定量描述。

目前关于反馈机制及能力的研究主要针对离散时间控制系统^[39], 这与离散时间控制器的广泛应用这一大趋势不谋而合, 并且一开始就考虑到了非参数不确定性, 因而具有较好的理论高度和普适性。反馈机制及能力给出了对不确定性系统的认识, 从理论上讲, 不是所有的未知系统都可以设计出稳定的自适应控制律^[40]; 用但是同时也留下了一个问题: 如果系统属于自适应反馈控制可稳定的范围内, 那么如何设计出合适的自适应反馈控制律使系统达到满意的性能? 一般来说, 不同的被控对象自然结构和参数都不同, 但是否存在一种较为通用的模型可以刻画大部分面对的被控对象? 可以类比经典控制理论, 毕竟线性系统和微分方程这些通用工具在几十年控制理论的发展中起到了关键的作用。类似这样的问题促进了半参数建模与分析的提出。

2.2 半参数系统

2.2.1 模型描述

虽然数字化控制器输出到被控对象的信号是离散时间，但是实际的过程是连续时间变化的。一般的离散时间非线性控制往往忽略了这一点，就导致这些研究侧重于理论和离散时间仿真分析。再次考虑下面的 NARX 系统

$$y_{k+1} = f(y_k, y_{k-1}, \dots, y_{k+1-p}, u_k, u_{k-1}, \dots, u_{k+1-q}) + \epsilon_{k+1} \quad (2.3)$$

在系统(2.3)中，把被控对象当成完全非线性模型，忽略了他们的线性特性，也就是说很多被控对象虽然具有较大的不确定性，但是在一定程度上是可以当作线性对象处理，只不过同时具有非线性部分，导致实际的线性部分参数与理论值有较大的偏差；对于不确定性系统，也就常常表现为同时具有参数不确定性和非参数不确定性。例如电机伺服系统简化处理就是一个二阶线性模型，一般的 PID 控制也可以获得还算不错的效果；只不过是在负载未知、快时变，或者一些难以建模的非线性动态特性如摩擦等严重的情况下，应用传统的 PID 控制电机伺服系统时，其效果才会大打折扣。

上述事实说明了实际系统表现出的线性特性有助于解决非线性自适应控制问题，不可忽视。这样看来，一般的非线性系统都可以看作是由线性部分和非线性部分组成。也就是说，在分析具有强非线性的不确定离散时间被控系统时，要同时考虑系统存在的参数不确定性和非参数不确定性。受反馈机制能力与极限等相关研究的启发，用半参数系统刻画非线性离散时间被控对象，然后基于半参数系统建立自适应控制律，是一种很自然的思路。

半参数分析和建模思路、方法是确定的，但是不同的被控对象得到的模型并不唯一。从后面的章节分析也可以看出这一点。本课题首先从离散时间角度，考虑如下的一类半参数系统

$$y_{k+1} = \theta^T \phi_k + u_k + f(\psi_k) + \epsilon_{k+1} \quad (2.4)$$

其中， y_k 、 u_k 分别表示系统在 k 时刻的输出和输入，由它们的历史数据组成的回归向

量 ϕ_k 和 ψ_k 具体定义如下:

$$\phi_k = [y_k, y_{k-1}, \dots, y_{k-p_1}, u_{k-1}, \dots, u_{k-q_1+1}]^\tau \quad (2.5)$$

$$\psi_k = [y_k, y_{k-1}, \dots, y_{k-p_2}, u_{k-1}, \dots, u_{k-q_2+1}]^\tau \quad (2.6)$$

参数部分和非参数部分涉及的回归向量不一定相同, 因此分别组合定义更具有一般性。再记

$$d_1 = p_1 + q_1 \quad (2.7)$$

$$d_2 = p_2 + q_2 \quad (2.8)$$

分别代表了回归向量 ϕ_k 和 ψ_k 的维数。

系统的输出 y_k 对应到实际的伺服电机系统中可能就是需要控制的电机转速或者位置等物理量, 而 u_k 可能就是控制电流 (或者控制力矩) 等。 $\theta \in \Theta$ 是未知参数向量, $f(\cdot) \in \mathcal{F}$ 是未知函数, $\epsilon_k \in \Delta_k$ 是外部随机干扰; 这里 Θ 、 \mathcal{F} 和 Δ_k 分别代表了参数不确定性 θ 、非参数不确定性 $f(\cdot)$ 和随机干扰 ϵ_k 的先验知识。他们都是集合的形式, 即 \mathcal{F} 是函数集合, Θ 是向量集合, Δ_k 是普通的数值集合。

上述的模型(2.4)直观地反映了被控系统的参数不确定性和非参数不确定性, 综合性和普适性较强。关于不确定性的先验知识也是半参数系统中的组成部分。下面分别对这三个量从数学关系上描述一些先验知识的例子。

2.2.2 先验知识举例

2.2.2.1 未知参数

记

$$\theta = [\theta_1, \dots, \theta_p]^\tau \quad (2.9)$$

一般来说, 未知参数向量 θ 具有很强的物理意义, 例如对应到伺服电机系统中, θ 中的某些分量可能就表示电机的力矩常数、电枢回路常数等。 θ 可能存在如下的某种先验知识:

- 除了向量的元素个数外, 没有其他任何关于未知参数的信息如上下界等;

- θ 各分量的上下界已知, 即 $\underline{\theta}_n \leq \theta_n \leq \bar{\theta}_n$, 其中 $\underline{\theta}_n$ 和 $\bar{\theta}_n$ 为已知的常数, $n = 0, 1, \dots, p$;
- 未知参数向量 θ 和标称向量 θ_0 之间的距离取值在一个范围内, 即 $\|\theta - \theta_0\| \leq r_0$, 这里 r_0 是一个已知的常数。
- 未知参数向量的取值有限可数, 即 θ 属于某一个已知的集合, $\theta \in \{\theta_1, \theta_2, \theta_3, \dots\}$;
- ...

2.2.2.2 未知函数

未知函数 $f(\cdot)$ 在实际系统如电机物理系统中, 对应可能就是难以建模的非线性摩擦力 (力矩)、高频振动特性等。 $f(\cdot)$ 可能存在如下的某种先验知识:

- $f(x) = 0$ 对于任意的自变量 x , 这意味着系统不存在任何未建模动态特性;
- $f(x)$ 的值受限于其他已知函数, 即 $\underline{f}(x) \leq f(x) \leq \bar{f}(x)$, 其中 $\underline{f}(x)$ 和 $\bar{f}(x)$ 为已知函数;
- 未知函数 $f(x)$ 和标称函数 $f_0(x)$ 之间的距离在某一个已知范围内, 即 $\|f(x) - f_0(x)\| \leq r_f$, 这里 $r_f \geq 0$ 是一个已知的常数, 这样函数 $f_0(x)$ 可以认为是定义在赋范可测函数空间中的集合 \mathcal{F} 的中心;
- 未知函数的表达式有限可数, 即 $f(x)$ 属于某一个已知的函数集合, $f(x) \in \{f_1(x), f_2(x), f_3(x), \dots\}$ 。
- 未知函数 $f(x)$ 是满足 Lipschitz 连续的, 即存在某个常数 $L_f \geq 0$, 使得对于不同的变量 x_1 和 x_2 $\|f(x_1) - f(x_2)\| \leq L\|x_1 - x_2\|$ 成立;
- 未知函数 $f(x)$ 是相对于自变量来说是单调递增 (或者递减) 的;
- 未知函数 $f(x)$ 是凸函数 (或者凹函数);
- ...

2.2.2.3 随机干扰

随机干扰一般来源于测量误差、空间电磁扰动等， ϵ_k 可能存在如下的先验知识：

- $\epsilon_k = 0$ 对于任意的 $k \geq 0$ ，这意味着系统不存在随机干扰；
- ϵ_k 的取值在一个已知的范围内，即上下界已知， $\underline{\epsilon} \leq \epsilon_k \leq \bar{\epsilon}$ ；
- ϵ_k 的取值受限于其他已知的干扰序列，即 $\underline{\epsilon}_k \leq \epsilon_k \leq \bar{\epsilon}_k$ ；
- ϵ_k 的取值都来自于一个已知的集合，即 $\epsilon_k \in \{\epsilonpsilon_1, \epsilonpsilon_2, \dots, \epsilonpsilon_N\}$ ；
- ϵ_k 的统计特性符合某种概率分布：例如 ϵ_k 是高斯随机过程，则 $E(\epsilon_k) = 0$ ， $E(\epsilon_k^2) = \sigma^2$ ；又比如 ϵ_k 的取值满足均匀分布，即 $\epsilon_k \sim U(0, 1)$ ；
- ϵ_k 是一个衰减的序列，如 $\epsilon_k = \frac{1}{k^2}$ ；
- ...

2.3 信息浓缩估计

2.3.1 提出背景

按照必然等价原理，为了控制系统(2.4)，需要辨识其中的未知参数向量 θ 。文献中已经存在很多经典的参数估计算法，例如递推最小二乘算法（Recursive Least Squares, RLS）、卡尔曼滤波（Kalman filter, KF）算法、最小均方算法（Least Mean Squares, LMS）等。不过这些算法大部分都是基于线性系统建立的估计算法，即便是存在某些非线性的推广，也没有统一的设计和应用思路。由于系统存在非参数部分 $f(\cdot)$ ，因此不能直接使用。实验数据^[10]表明，在非线性对象中盲目使用基于线性系统的参数估计算法会导致估计结果偏差较大，特别是在强非线性系统中。

被研究的系统(2.4)经常存在随机干扰。在系统辨识、信号处理、随机逼近、状态估计以及传统的自适应控制等领域中^[8]，基于噪声或者干扰统计特性的参数估计算法应用十分广泛。随机干扰是系统的一种不确定性，为了描述和设计相应的参数估计算法，总是假设被研究的系统中的随机干扰符合某种统计特性。这是利用先验知识转化为可描述的数学关系的方法。本文在2.2.2.3中也把统计特性作为先验知识的例子说明。事实上，随机干扰可能存在若干种来源，导致这些干扰或误差的概率分布（如果

存在)并不符合模型假定的特性,最终使得这些估计算法在实际应用过程中失效。例如,如果对随机干扰的先验知识没有深入了解或测量,一种普遍的做法是假设其干扰服从某种高斯分布。这种做法在很多情况下确实有效,结果较为准确,但是对于有些情况可能就会偏离很远。为了使结果准确,可能需要调节高斯分布的方差等参数。

在实际工程中,随机干扰的数值往往较小(如果较大,就得考虑把他当作非线性部分了),且一般可以不会超过某个已知范围,对应2.2.2.3中的第2个例子。这不是一种基于概率统计的先验知识,能够比较准确地反映真实的情况。比如在某个伺服电机系统中的电磁干扰导致的脉动力矩,一般不会超过某个幅值。和随机干扰类似,系统的非参数部分 $f(\cdot)$ 部分的先验知识也常常是一个范围,即区间的形式。例如,经过一定的分析和实践,电机的摩擦力不会超过某个数值,多关节机器人动力学中重力补偿等非线性项也是一个有限值。

经过理论分析和实践积累了大量关于被控对象的先验信息,大多都是可以用集合描述的,而传统的基于数值的估计算法难以利用基于集合的先验知识。因此,由于上面种种因素的存在,需要另辟蹊径解决系统(2.4)的参数估计问题。

2.3.2 主要思想

为了实现参数估计,可以充分利用系统的先验信息。从2.2.2.1到2.2.2.3介绍的先验知识可以看出,对参数向量 θ 、非参数部分 $f(\cdot)$ 、随机干扰 ϵ 等不确定性的等价数学描述一般都是表现为集合的形式,因此设计基于集合的参数估计是一种自然的思路。文献[10]中提出的信息浓缩估计就是这样的一类估计算法。

信息浓缩估计是一种针对离散时间系统的基于集合的参数估计器,其主要思想是从初始的关于参数的先验集合出发,将每一时刻的先验知识都看作是对未知函数和参数的数学约束,然后结合采集到的真实的输入输出数据剔除掉不符合真实数据的取值,逐渐缩小这个先验集合的大小,也就减少了系统的参数不确定性;这样经过足够长的时间和数据筛选之后,理论上可以从参数集合中选择任意值或者根据一定的规则选择最优值作为最终的参数估计。

下面基于数学语言详细解释信息浓缩估计器的具体思路。这里再次考虑系统

$$y_{k+1} = \theta^T \phi_k + u_k + f(\psi_k) + \epsilon_{k+1}, \quad (2.10)$$

并记

$$\begin{aligned} z_k &= f(\psi_k) + \epsilon_{k+1} \\ &= y_k - \theta^\tau \phi_k - u_{k-1} \end{aligned} \quad (2.11)$$

这个被控对象具有先验知识 $\theta \in \Theta \subseteq \mathcal{R}^{d_1}$, $z_k \in V_k$ 。第一项是关于参数的先验集合, 可以作为参数在初始状态的估计, 记作

$$I_0 = \Theta \quad (2.12)$$

这样, 在时刻 k , 随着 ϕ_k 、 y_k 和 u_k 等数据的获得 (经过简单计算可以获得 z_k), 可以定义如下所谓的信息集合 I_k 的表达式为

$$I_k \triangleq \{\theta \in \Theta: y_k - \phi_{k-1}^\tau \theta - u_{k-1} \in V_k\} \quad (2.13)$$

然后定义如下的信息浓缩集合

$$C_k = \bigcap_{j=0}^k I_k \quad (2.14)$$

写成递推的形式为

$$C_k = C_{k-1} \cap I_k \quad (2.15)$$

可以定义初始的集合为

$$C_0 = I_0 = \Theta \quad (2.16)$$

其中, C_k 也就是每个时刻 k 的参数集, 可以从中选择任意值作为参数估计参与后续计算, 不过对于这种区域形式, 一般选择中心点作为每个时刻的参数估计值相对比较准确。

命题 2.1. 经过分析, 容易得到信息浓缩估计器有如下数学性质:

1. 信息集合 I_k 的定义跟具体的模型有关, 形式不唯一;
2. 单调性, 即相邻时刻的参数估计集合之间满足如下关系:

$$C_0 \supseteq C_1 \supseteq C_2 \supseteq \dots; \quad (2.17)$$

3. 收敛性, 经过足够长的时间后, 参数估计集合序列 C_k 满足:

$$C_\infty = \bigcap_{k=0}^{\infty} C_k \quad (2.18)$$

4. 集合 C_∞ 非空的充分必要条件是, 系统的模型和相应的先验知识以及参与计算的输入输出数据是完全匹配的。

命题2.1最后两条的具体含义是: 如果模型和相应的先验知识以及参与计算的数据是完全正确的, 那么 C_∞ 必定是一个非空集合, 并且满足真实的参数向量 $\theta \in C_\infty$, 集合 C_∞ 的任意一个元素都可以匹配模型和数据; 反过来, 也成立。但是, 如果 $C_\infty = \emptyset$ 说明参与计算的数据、模型设置或者先验知识中某个部分存在问题, 不是相对应的, 那么就会导致结果出现偏差。这个充要条件一般来说比较容易满足的, 可以把先验知识设定足够宽泛, 并保证参与计算的数据都来源于真实的系统, 至于野值的出现属于数据和信息预处理的问题, 就不是本文要考虑的范畴了。

2.3.3 典型实现

从上面一小节2.3.2关于信息浓缩估计器的描述和举例中, 可以看出信息浓缩估计是一种在线实时估计器, 充分利用了系统的先验知识和实时数据, 因此也可以看作是一种数据驱动型的估计算法。随着采集到的数据不断增多, 未知参数的不确定性就越来越小, 我们对参数的估计就越来越准确。系统关于参数的先验知识不同, 会导致信息集合 I_k 和信息浓缩之后的参数估计集合 C_k 不同, 因而关于其中的递归运算(2.15)也就不同。

有一种十分典型的情形, 如同在上述的提出背景2.3.1中描述的 $z_k \in V_k$ 是区间的形式。具体数学描述为

$$\underline{\theta}_n \leq \theta_n \leq \bar{\theta}_n \quad (2.19)$$

$$\underline{z} \leq z_k \leq \bar{z} \quad (2.20)$$

这里, z_k 是(2.11)定义的非参数部分 $f(\cdot)$ 和随机干扰 ϵ_k 的和, z_k 的上下界也就是这两个量的上下界的组合。为了便于后面的计算, 这里直接考虑他们的组合形式 z_k 。

本节首先考虑这种先验知识的系统。信息浓缩估计器主要就是求出每一步的参数

估计集合 C_k 。文献 [10] 设计了一维情形下 $d_1 = 1$ 的参数估计算法，即 θ 是标量的情形。

2.3.3.1 一维参数算法

这里首先介绍 d_1 为 1 时 C_k 的计算方法。当 $d_1 = 1$ 时， θ 和 ϕ_k 都是标量。由方程(2.13)可知

$$I_k \triangleq \{\theta \in \Theta: \underline{z} \leq y_k - \phi_{k-1}\theta - u_{k-1} \leq \bar{z}\} \quad (2.21)$$

解上面的不等式得到

$$y_k - u_{k-1} - \bar{z} \leq \theta\phi_{k-1} \leq y_k - u_{k-1} - \underline{z}. \quad (2.22)$$

如果 $\phi_{k-1} \neq 0$ ，则

$$\theta \in [\underline{s}_k, \bar{s}_k] \quad (2.23)$$

其中定义


$$\begin{aligned} \underline{s}_k &= \frac{\min(\text{sign}(\phi_{k-1})(y_k - u_{k-1} - \bar{z}), \text{sign}(\phi_{k-1})(y_k - u_{k-1} - \underline{z}))}{\phi_{k-1}} \\ \bar{s}_k &= \frac{\max(\text{sign}(\phi_{k-1})(y_k - u_{k-1} - \bar{z}), \text{sign}(\phi_{k-1})(y_k - u_{k-1} - \underline{z}))}{\phi_{k-1}} \end{aligned} \quad (2.24)$$

$\text{sign}(\cdot)$ 是常见的符号函数，定义如下：

$$\text{sign}(x) = \begin{cases} 1, & x > 0 \\ 0, & x = 0 \\ -1, & x < 0 \end{cases} \quad (2.25)$$

一般来说， C_0 直接由先验知识 Θ 给出一个区间范围。在时刻 k ，由方程(2.14)得到信息浓缩集合（参数集）为

$$C_k = [\underline{h}_k, \bar{h}_k] \quad (2.26)$$


 图 2.1 $d_1 = 1$ 时，信息浓缩过程的几何解释

其中 \underline{h}_k 和 \bar{h}_k 的递推表示形式为

$$\begin{aligned}\underline{h}_k &= \max(\underline{h}_{k-1}, \underline{s}_k) \\ \bar{h}_k &= \min(\bar{h}_{k-1}, \bar{s}_k)\end{aligned}\tag{2.27}$$

经过上面的推导，(2.24)，(2.26)和(2.27)就是 $d = 1$ 情形下的信息浓缩参数算法的具体公式，上面的过程可以表示为图2.1。

2.3.3.2 多维参数情形

当 $d_1 > 1$ 时， $\boldsymbol{\theta}$ 和 $\boldsymbol{\phi}_k$ 都是向量，和方程(2.21)类似可以得到

$$\boldsymbol{\phi}_{k-1}^\tau \boldsymbol{\theta} \in [y_k - u_{k-1} - \bar{z}, y_k - u_{k-1} - \underline{z}].\tag{2.28}$$

上面的区间形式可以写成下面关于参数向量 $\boldsymbol{\theta}$ 的两个不等式

$$\begin{aligned}\boldsymbol{\phi}_{k-1}^\tau \cdot \boldsymbol{\theta} &\leq y_k - u_{k-1} - \bar{z} \\ (-\boldsymbol{\phi}_{k-1}^\tau) \cdot \boldsymbol{\theta} &\leq -(y_k - u_{k-1} - \underline{z})\end{aligned}\tag{2.29}$$

从几何上看，方程组(2.29)中的任意一个线性不等式的解，都代表着一个定义在域 \mathcal{R}^{d_1} 上的广义半平面。因此，通常来说，关于同一向量 $\boldsymbol{\theta}$ 的多个线性不等式的解在

在几何上表示为一个广义多边形或者多面体，仅需要找出这个多面体的顶点（向量描述）就可确定这个多面体。特别的， $d_1 = 2$ 时，多个方程组(2.29)的解就是平面上一个普通多边形，确定了这个多边形的顶点就等价于确定了参数满足的集合 C_k 。

记

$$\Gamma_k = \{P_n, n = 1, 2, \dots, N_k\} \quad (2.30)$$

为定义在区域 C_k 上的多面体顶点集合，其中 P_n 代表某个顶点，第 k 时刻集合 Γ_k 包含 N_k 个顶点。这里 Γ_k 记为一个多面体。这里的顶点集情况是对于 $d_1 > 2$ 时有意义。下面先给出多维情形的一般计算方法。

由方程(2.14)可知，从约束条件来看，集合 C_k 比 C_{k-1} 多了一组不等式

$$\begin{aligned} \phi_{k-1}^\tau \cdot \theta &\leq v_{k,1} \\ (-\phi_{k-1}^\tau) \cdot \theta &\leq v_{k,2} \end{aligned} \quad (2.31)$$

其中

$$\begin{aligned} v_{k,1} &= y_k - u_{k-1} - \underline{z} \\ v_{k,2} &= -(y_k - u_{k-1} - \bar{z}) \end{aligned} \quad (2.32)$$

本文称(2.31)为线性约束。和 $d_1 = 1$ 情形类似，可以得到信息约束的递推形式为

$$\begin{aligned} \Gamma'_{k-1} &= G(\Gamma_{k-1}, \phi_{k-1}, v_{k,1}) \\ \Gamma_k &= G(\Gamma'_{k-1}, \phi_{k-1}, v_{k,2}) \end{aligned} \quad (2.33)$$

这里 $G(\Gamma, \phi, f)$ 代表一种变换（算法），它表示在初始的多面体 Γ 中加入一个线性约束条件 $\phi \cdot \theta \leq v$ 。

图2.2展示了 $d_1 = 2$ 时 G 变换的过程。图中，原有的参数区域是由顶点集

$$\{P_1, P_2, P_3, P_4, P_5\} \quad (2.34)$$

围成的多边形，加入线性约束条件 $\phi \cdot \theta \leq v$ 之后，变成了顶点集

$$\{P'_1, P'_2, P_3, P_4, P_5\} \quad (2.35)$$

围成的多边形（深色部分）。




图 2.2 $d_1 = 2$ 时，信息浓缩 G 变换过程的几何解释

可以看出，多边形的面积在原来的基础上缩小了，即参数的可行域减少了，参数不确定性随着也就减少了。不过图2.2只是线性约束和多边形位置的一种情况，因为很可能直线 L 和多边形没有交点，那么经过这个时刻的信息浓缩后，参数集合不变。因此在设计算法实现时需要考虑周全，否则可能导致 $C_\infty = \emptyset$ 的出现。

$d_1 > 2$ 时高维情形的情况类似，只是多边形变成了多面体，直线变成了广义半平面，由于多维情形不容易形象描述，此处就不再一一画出图形说明。

2.4 本章总结

本章的主要内容是半参数系统和信息浓缩估计的基本思想和计算方法。首先由关于已有的反馈机制能力极限的探索和研究，引出存在多种不确定性系统的自适应控制问题；然后从一系列具有共性特点的实际问题中，抽象出半参数系统的基本模型，介绍了相关的先验知识举例；接着介绍了一种基于集合的参数估计算法，即所谓的信息浓缩估计的主要思想；最后针对典型系统，介绍了信息浓缩估计的具体实施框架，和相应的计算流程。

第3章 二维参数的信息浓缩估计算法

设计高阶情形下基于信息浓缩思想的参数估计算法是实现半参数自适应控制的前提。现有的半参数自适应控制实现了一维情形下的参数估计算法，但二阶及其以上的参数估计并未具体实现，这涉及计算几何的知识。上一章介绍了半参数系统中的信息浓缩估计方法，从相关的定理2.1可知不同的先验知识会导致信息集合 I_k 的形式不同。一维情形由于只有一个参数不涉及顶点集的组合，因而具体算法比较容易实现，上面第2.3.3.1已经给出具体计算步骤。但是实际情况往往不只有一个参数，因而需要设计多维情形的估计算法，第2.3.3.2小节给出了实施框架。多维情形的算法如果直接通过代数推导，不容易解决，需要借助计算几何的思想。在许多运动控制系统中，二阶情形十分常见。因此本章针对两个参数即 $d_1 = 2$ 的情形，设计信息浓缩估计器的具体算法。

3.1 问题描述

在第二章的基础上，本章继续考虑非参数部分具有上下界这种典型的先验信息。如前所述，需要针对关联这种先验知识的系统设计信息浓缩估计算法，完整的过程主要以下分为两步：

1. 信息浓缩。在上一个时刻的基础上，根据这个时刻的输入输出数据得到的约束，确定这个时刻的信息浓缩之后的参数集合。
2. 选定合适值。根据一定的法则，从上述的参数集合中选择合适的估计值作为这个时刻的参数估计值参与控制律等后续的计算。

第一步的具体操作是在某个确定时刻，得到一组输入输出数据，可以确定两个线性约束不等式，将这两个约束先后加入到之前时刻的顶点集合中，得到这一时刻的顶点集合，也就确定了当前时刻的参数集合。从理论上说，第一步得到的参数集合中的每一个值都可以作为这个时刻的估计值，但是控制律等后续计算往往需要一个具体的值，所以需要按照一定的法则从集合中确定一个最优值，一般选择多边形的中心作为这个时刻的估计值。上面的两步中，第一步信息浓缩是难点。因此，本章的重点在于第一步的算法设计。一个时刻的信息浓缩过程包含两组约束关系的先后加入，也就是

两次 G 变换。这两次的变换过程一样，只是每次的数据不一样，故这里只需要考虑一次变换。另外，为了叙述方便，本章关于时刻 k 的下标省略。

$d_1 = 2$ 时，用 Γ 和 Γ' 分别表示两个不同的多边形，其顶点集合表示（按顺时针排列，下同）为

$$\Gamma = \{P_1, P_2, \dots, P_N\}$$

$$\Gamma' = \{P'_1, P'_2, \dots, P'_{N'}\}$$

$d_1 = 2$ 时，关于未知参数 θ 的约束不等式为

$$\phi^\tau \cdot \theta \leq e \quad (3.1)$$

这里 ϕ 和 θ 都是二维向量， ϕ 和 e 都可以由输入输出组合得到， θ 是这个不等式的未知变量。

因此，变换 $G(\Gamma, \phi, e)$ 可以记为映射

$$\text{AddLinear2D}: \Gamma \rightarrow \Gamma' \quad (3.2)$$

这就是二维参数的信息浓缩估计算法需要解决的核心部分。

3.2 几何关系分析

二维情形下主要是考虑同一个平面内，直线和多边形的位置关系。图2.2展示了直线和多边形位置关系的一种可能的例子，从这个图中可以知道求解这个顶点集涉及到计算几何的知识，需要全面考虑各种情形。具体来看，分析一条直线和多边形的位置关系，就是考察多边形中每个顶点和直线的位置关系。单个顶点和直线的位置关系主要涉及平面解析几何的知识。

$d_1 = 2$ 时， $\phi^\tau \cdot \theta = v$ 表示一条直线 L ，它将整个平面分成两个半平面。用二元组

$$L_c = (\phi, \theta)$$

表示不等式约束关系

$$\phi^\tau \cdot \theta \leq v \quad (3.3)$$

在几何上, L_c 也可以被认为是一个半平面。

记

$$\phi^T = [\phi_1, \phi_2]$$

顶点 P_n 的坐标为

$$P_n: (X_{P_n}, Y_{P_n})$$

分别对应于待估计参数向量 θ 的第一个分量和第二个分量。顶点 P_n 和直线 L 的位置关系可以由下面的不等式确定

$$\phi_1 X_{P_n} + \phi_2 Y_{P_n} \leq v \quad (3.4)$$

如果不等式(3.4)成立, 则顶点 P_n 满足约束关系(3.3), 即在半平面 L_c 内; 否则, 顶点 P_n 不在半平面 L_c 内。根据不等式(3.4)可以确定多边形 Γ 的所有顶点和直线 L 的位置关系, 从而判断出这个多边形和直线的位置关系。

经过分析, 根据各个顶点和直线的分布情况, 可以将多边形和直线的位置关系分为三类。

1. 多边形顶点在直线的同一侧, 则多边形和直线没有交点, 如图3.1所示又可具体分为两种情况。第一种情况3.1(a), 多边形不变, 即 $\Gamma' = \Gamma$; 第二种情况3.1(b), 一般是在数据出错的情况下才会发生(在定理(2.1)已经指出), 此时 $\Gamma' = \emptyset$, 算法停止。






图 3.1 直线和多边形位置关系的第一类情形

2. 多边形只有一个顶点和其他顶点不在直线的同一侧，如图3.2所示又可具体分为两种情况。第一种情况3.2(a)，只有一个顶点不满足约束，多边形顶点个数加 1；第二种情况3.2(b)，只有一个顶点满足约束，多边形变成一个三角形。




(a) 情形 2.1




(b) 情形 2.2

图 3.2 直线和多边形位置关系的第二类情形

3. 多边形有至少两个顶点和其他顶点不在直线的同一侧，如图3.2所示又可具体分为两种情况。图3.3(a)和3.3(b)是两种对立的情形，事先都无法准确知道剩余的顶点个数，只能根据实际情况确定。



(a) 情形 3.1



(b) 情形 3.2

图 3.3 直线和多边形位置关系的第三类情形

3.3 算法实现

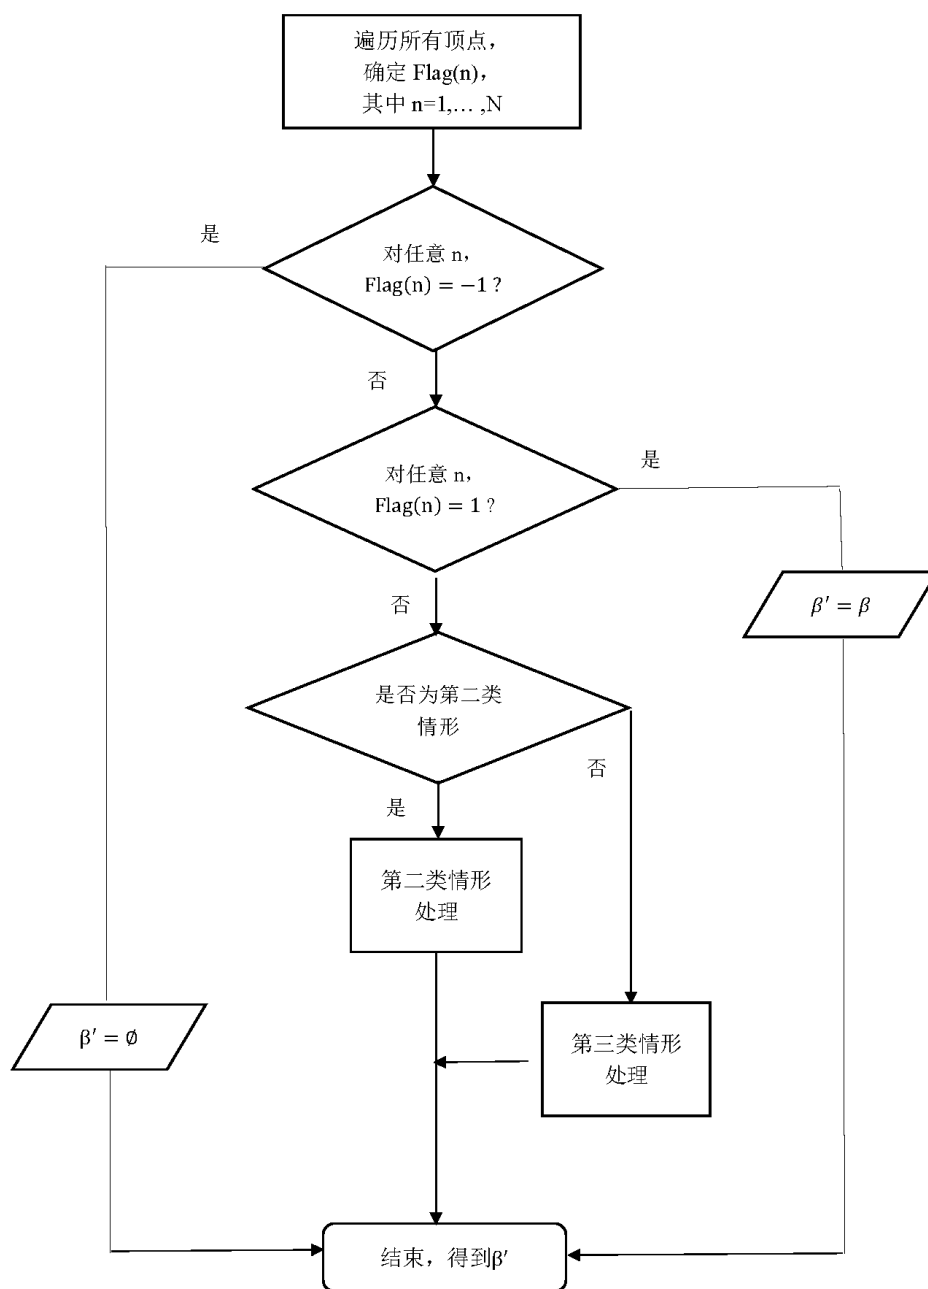


图 3.4 AddLinear2D 的算法流程图

根据上节关于多边形和直线的几何位置关系的分析和总结，本节设计了 $d_1 = 2$ 时多边形顶点集变换 AddLinear2D 的计算几何算法。

需要遍历多边形的所有顶点与多边形的位置关系。可以用一个数组记录顶点 P_n 和约束 L_c 的位置关系，即

$$\text{Flag}(n) = \begin{cases} 1, P_n \in L_c \\ -1, P_n \in L_c \end{cases} \quad (3.5)$$

这里， $n = 1, 2, \dots, N$ 。

根据上节的位置关系结果，设计算法的流程如图3.4所示。最后写出具体过程伪代码实现见算法3.1。

算法 3.1. AddLinear2D

输入: $\Gamma = \{P_1, P_2, \dots, P_N\}$

输出: $\Gamma' = \{P'_1, P'_2, \dots, P'_{N'}\}$

Denote the number of vertices in Γ by N

for $j = 1$ to N **do**

Denote the j th vertex by P_j

Let $F_j = \text{sgn}(c - \phi^T P_j)$

end for

if $F_j \geq 0 \forall 1 \leq j \leq n$ **then**

$\Gamma' \leftarrow \Gamma$ and return

else if $F_j < 0 \forall 1 \leq j \leq n$ **then**

$\Gamma \leftarrow \emptyset$ and return

end if

for $j = 2$ to $N - 1$ **do**

if (P_j and P_{j-1} are in different sides) \wedge (P_j and P_{j+1} are in different sides) **then**

$P_1^i \leftarrow$ the intersection of l_i and $\overline{P_{j-1}P_j}$

$P_2^i \leftarrow$ the intersection of l_i and $\overline{P_{j+1}P_j}$.

if ($F_j > 0$) **then**

$\Gamma' = \{P_1^i, P_j, P_2^i\}$

else

$\Gamma' = \{P_1, \dots, P_{j-1}, P_1^i, P_2^i, P_{j+1}, \dots, P_n\}$

end if

```

    break
else if ( $P_j, P_{j-1}$  are in different sides)  $\wedge$  ( $P_j, P_{j+1}, \dots, P_{j+a-1}$  are on the same side)  $\wedge$ 
( $P_{j+a-1}, P_{j+a}$  are on different sides) then
     $P_1^i \leftarrow$  the intersection of  $l_i$  and  $\overline{P_{j-1}P_j}$ 
     $P_2^i \leftarrow$  the intersection of  $l_i$  and  $\overline{P_{j+a-1}P_{j+a}}$ .
    if ( $F_j > 0$ ) then
         $\Gamma' = \{P_1^i, P_j, \dots, P_{j+a-1}, P_2^i\}$ 
    else
         $\Gamma' = \{P_1, \dots, P_{j-1}, P_1^i, P_2^i, P_{j+a}, \dots, P_n\}$ 
    end if
    break
else if ( $P_j, P_{j+1}$  are in different sides)  $\wedge$  ( $P_j, P_{j-1}, \dots, P_{j-b+1}$  are on the same side)  $\wedge$ 
( $P_{j-b+1}, P_{j-b}$  are on different sides) then
     $P_1^i \leftarrow$  the intersection of  $l_i$  and  $\overline{P_{j-b+1}P_{j-b}}$ 
     $P_2^i \leftarrow$  the intersection of  $l_i$  and  $\overline{P_{j+1}P_j}$ .
    if ( $F_j > 0$ ) then
         $\Gamma' = \{P_1^i, P_{j-b+1}, \dots, P_j, P_2^i\}$ 
    else
         $\Gamma' = \{P_1, \dots, P_{j-b}, P_1^i, P_2^i, P_{j+1}, \dots, P_n\}$ 
    end if
    break
end if
     $j \leftarrow j + 1$ 
end for
return  $\Gamma'$ 

```

算法3.1实现了第3.1中提到的信息浓缩估计的第一步。对于第二步，一般选择多

边形 Γ' 的中心作为参数估计值 $\hat{\theta}$ ，即

$$\begin{aligned}\hat{\theta}_1 &= \frac{1}{N} \sum_{n=1}^N X_{P'_n} \\ \hat{\theta}_2 &= \frac{1}{N} \sum_{n=1}^N Y_{P'_n}\end{aligned}\tag{3.6}$$

本节设计的算法3.1和方程(3.6)就是 $d_1 = 2$ 时完整的信息浓缩估计算法，可以用于后续的控制设计。

3.4 仿真实例

为了验证本章设计算法的有效性，本节在实际的被控对象中仿真上面设计的信息浓缩估计算法。选择如下的被控对象

$$y_{k+1} = \theta_1 \cdot y_k + \theta_2 \cdot y_{k-1} + u_k + \epsilon_{k+1} + \sin\left(\frac{k}{2}\right)\tag{3.7}$$

其中 $\theta_1 = -0.5$ ， $\theta_2 = 0.5$ 。随机干扰取为均匀分布，即

$$\omega_k \in U(0, 1)$$

则随机干扰的上下确界为

$$0 \leq \omega_k \leq 1$$

而非线性部分是三角函数，其上下界为

$$-1 \leq \sin\left(\frac{k}{2}\right) \leq 1$$

为了便于计算，令 $u_k = 0$ 。在本节中，为了更加符合实际情况，在计算时，将随机干扰和非线性的上下界范围扩大，分别取为

$$-1 \leq \omega_k \leq 2$$

和

$$-2 \leq \sin\left(\frac{k}{2}\right) \leq 2$$

因此，合并得到

$$\underline{z} = -3, \bar{z} = 4$$

初始的参数集合取为

$$\Theta = \{-1 \leq \theta_1 \leq 1, -1 \leq \theta_2 \leq 1\}$$

仿真到第 $k = 500$ 时，得到的多边形如图3.5所示，分别以两个参数代表横纵坐标，红色圈点代表真实值 θ 在几何上的表示，星形点代表了估计值 $\hat{\theta}$ 在几何上的表示。画出整个仿真过程的参数估计曲线如图3.6所示。从这个图中可以看出，参数估计值接近真实值。




图 3.5 当 $d_1 = 2$ 时仿真实例中 $k = 500$ 时的多边形及参数估计

3.5 优化问题

在信息浓缩估计方法中，关键的问题在于计算每一步（时刻 k ）的信息集 I_k 和信息浓缩集 C_k 。从上面的讨论中，可以看出 $d_1 = 1$ 时很容易解决这两个集合的计算问题。然而，当 $d_1 > 1$ 时，通常情况下集合 C_k 中的顶点个数 N_k 随着 $k \rightarrow \infty$ 会不断增




图 3.6 当 $d_1 = 2$ 时仿真实例中的参数估计曲线（信息浓缩估计算法）

长，特别是高维情形 $d_1 \geq 3$ 时。因此，有可能在实际应用中，随着 $k \rightarrow \infty$ ，信息浓缩估计过程需要的内存会无限增长，这是一个十分致命的问题，需要优化。

其实，随着 $k \rightarrow \infty$ ， C_k 的范围是在不断缩小的，即使顶点个数可能会增加。因此，为了克服顶点个数无限增长的问题，在实际应用中，可以不需要如此多的顶点来精确的表示信息浓缩集 C_k 。也就是说，在多维情形中，在每个时刻 k 的 G 变换过程中，可以用具有足够少顶点个数 N_L 的集合 \hat{C}_k 来近似 C_k 。

一般有两种优化策略，这里主要介绍被称为信息浓缩估计算法的“松实现”（Loose IC estimator, Loose-IC），另外一种“紧实现”（Tight IC estimator, Tight-IC）。Loose-IC 的具体要求是，对于任意的 k ，都满足 $\hat{C}_k \supseteq C_k$ 。

记


$$\hat{C}_\infty = \bigcap_{k=1}^{\infty} \hat{C}_k,$$

则


$$C_\infty = \bigcap_{k=1}^{\infty} C_k \subseteq \hat{C}_\infty \quad (3.8)$$

上面方程(3.8)意味着，Loose-IC 在实施过程中不会丢弃任何可能的参数值。对于 $d_1 = 2$ 这种二维情形，为了便于计算，一般选择顶点个数 $N_L = 3$ 或者 $N_L = 4$ ，分别

如图3.7(a)和3.7(b)所示。从图中可以看出，顶点个数的减少和多边形的简化，意味着计算复杂度的降低，实现较好的优化效果。



(a) 用三角形近似多边形



(b) 用矩形近似多边形

图 3.7 $d_1 = 2$ 时 Loose-IC 的实现途径

3.6 主要特点

从上面的讨论和仿真实例中，可以总结出信息浓缩估计算法有如下优点：

1. 充分利用先验信息和后验数据产生的信息。理想情况下没有任何的信息被浪费掉，而一般传统的辨识算法仅仅利用了部分先验信息和某些随机先验假设。
2. 这是基于集合的估计，实际上每次给出的是一个参数可行的集合，不同于最小二乘算法等给出的点估计，即单个值。这样一方面可以获得比较全面的参数信息，另一方面可以衡量估计值的准确性。
3. 随着时间的增长，逐步找出最优（最有可能的）参数估计值。在参数估计过程中，同时可以用于检查实际采集的数据和系统模型的先验信息的一致性。

4. 可以针对随机系统，也可以处理非统计语言描述的先验信息，不受限于概率模型。
5. 具体实施比较灵活，主要取决于先验信息的具体表现形式，这也给算法的优化带来了极大的提升空间。例如为了降低计算复杂度，可以用上节讨论的“松实现”。
6. 不像传统辨识算法一样，在某些时候表现出随着时间的推移，估计值漂移或者精度下降的现象。相反，数据越多，估计越准确。

一般事物总存在两面性，经过分析，信息浓缩估计算法也存在如下问题：

1. 难以利用系统干扰项的先验信息，特别是无界随机干扰。也许在这种没有非参数不确定性且随机干扰是无界噪声序列时，传统基于值估计的算法表现得更加适合。
2. 实际的算法效率依赖于先验信息的利用程度和具体实现。一般情况下，由于信息浓缩估计算法涉及到计算几何过程（也许有其他的实施策略），因而其计算复杂度和设计难度要稍大于 RLS 等传统辨识算法。毕竟后者一般只会涉及到矩阵的加减乘除运算。
3. 目前不存在针对信息浓缩估计算法的显示表达式或者固定的公式，同时，基于集合的辨识思路给具体控制系统的应用和闭环稳定性分析带来了一定的困难。

虽然存在诸如此类的缺点，但信息浓缩估计算法仍然提供了很好的辨识思路和较好的收敛性和精确度，值得深入研究和进一步优化。

3.7 本章总结

本章主要讨论了信息浓缩估计算法的具体实现。首先描述了二维参数情形下，信息浓缩估计算法的主要步骤和基本问题；然后对信息浓缩变换中直线和多边形的几何关系进行了详细地分析，同时设计了信息浓缩变换的算法流程图，并给出了具体的伪代码实现；接着在实际的被控对象中仿真前面设计的信息浓缩估计算法，给出了最终估计结果和过程曲线；最后讨论了信息浓缩估计的计算复杂度优化问题，总结了信息浓缩估计的主要优缺点。

第4章 离散时间半参数自适应控制

自适应控制中的辨识是为了控制问题，上一章设计了二维情形下的信息浓缩估计算法去辨识线性部分的未知参数。本章将在第三章的基础上设计非参数部分的估计算法，主要借助于一种机器学习算法，然后根据两部分不确定性的估计结果设计自适应控制律，解决随动控制问题。

4.1 问题描述

再次考虑第二章给出的半参数模型

$$y_{k+1} = \theta^T \phi_k + u_k + f(\psi_k) + \epsilon_{k+1} \quad (4.1)$$

其中， θ 是未知参数向量， $f(\cdot)$ 是未知函数。同理，令

$$z_k = f(\psi_k) + \epsilon_{k+1} \quad (4.2)$$

针对系统(4.1)，自适应估计与控制问题的一般表述是：给定关于 θ ， $f(\cdot)$ 和 ϵ_{k+1} 的先验信息，在 k 时刻，如何根据实时产生的一系列输入输出数据 $\{y_k, u_k; k = 1, 2, \dots\}$ ，去估计未知参数 θ 和 z_k ？然后根据 θ 和 z_k 的估计（预测）值去设计合适的自适应控制输入 u_k 使得 $k+1$ 时刻的输出 y_{k+1} 能跟踪上期望的输出 y_{k+1}^* 。

本章针对系统(4.1)有如下先验信息：

- 期望跟踪信号 $\{y_k^*\}$ 是有界的，即存在有界正常数 B_{yd} ，使得

$$|y_k^*| \leq B_{yd}, \forall k \geq 0. \quad (4.3)$$

- θ 各分量是有界的，即 $\underline{\theta}_j \leq \theta_j \leq \bar{\theta}_j$ ，其中 $\underline{\theta}_j$ 和 $\bar{\theta}_j$ 为已知的常数， $j = 1, 2, \dots, d_1$.
- 噪声序列 ϵ_k 的取值在一个已知的范围内，即

$$\underline{\epsilon} \leq \epsilon_k \leq \bar{\epsilon}, \forall k \geq 0. \quad (4.4)$$

- 未知函数 $f(\cdot)$ 的上下界受限于其他已知函数，即

$$\underline{f}(\psi) \leq f(\psi) \leq \bar{f}(\psi). \quad (4.5)$$

第三章已经给出了 θ 的估计算法，因此剩下的部分可以分为两个核心问题，一方面是设计 $f(\cdot)$ 的估计算法，另一方面是设计控制输入 u_k 的表达式。假设第二章设计出的未知参数的估计值为 $\hat{\theta}_k$ ，下面需要设计出 \check{z}_k 的表达式。因此，根据必然等价原理，设计出的控制输入的一般表达式为：

$$u_k^* = y_{k+1}^* - \phi_k^T \cdot \hat{\theta}_k - \check{z}_k \quad (4.6)$$

非线性部分的辨识与控制器的设计是本章要重点解决的问题。

4.2 非参数部分的估计

4.2.1 最近邻估计

前面的章节用信息浓缩估计解决了参数不确定性的辨识问题，现有的半参数自适应控制方法针对非参数部分使用的是最近邻估计，其针对的主要是一维参数情形 ($d_1 = 1$ 且 $d_2 = 1$)，即下面的一维半参数系统

$$y_{k+1} = \theta y_k + u_k + f(y_k) + \epsilon_{k+1} \quad (4.7)$$

这里，标量 θ 是未知的，为系统的参数不确定性部分，同样 $f(\cdot)$ 是非参数不确定性部分，满足 Lipschitz 条件。最近邻估计不显式地估计 $f(\cdot)$ 部分，而是直接估计

$$\eta_k = \theta y_k + f(y_k) \quad (4.8)$$

这个整体。这样，在用信息浓缩算法估计出参数 θ 之后，移除这个估计值 $\hat{\theta}$ ，就可以获得非参数部分的估计。

在系统(4.7)中，由于 Lipschitz 条件的存在，不管是非参数部分还是参数部分都主要和输出值 y_k 相关，这样输出值 y_k 相近的时刻，那么 η_k 的值也应该相差不大。因此最近邻估计就主要利用到了这一点，其主要思想在于寻找和当前时刻输出值 y_k 最相

近的时刻，然后进行比较计算。

首先定义最近邻时刻为

$$i_k \triangleq \arg \min_{i < k} |y_k - y_i| \quad (4.9)$$

i_k 是历史输出值中和当前时刻最接近的时刻。那么有如下等式成立

$$\begin{aligned} \eta_k &= \eta_k - z_{i_k} + z_{i_k} \\ &= [\theta y_k + f(y_k)] - [\theta y_{i_k} + f(y_{i_k}) + w_{i_k+1}] + z_{i_k} \\ &= [\theta(y_k - y_{i_k}) + z_{i_k}] + [f(y_k) - f(y_{i_k}) - w_{i_k+1}] \end{aligned}$$

一般来说，上面等式中的最后一行中 $f(y_k) - f(y_{i_k})$ 的值接近零，并且干扰项比较小。因此，可以取整体表达式(4.8)的估计为

$$\hat{\eta}_k \triangleq \hat{\theta}_k(y_k - y_{i_k}) + z_{i_k} = \hat{\theta}_k(y_k - y_{i_k}) + (y_{i_k+1} - u_{i_k}) \quad (4.10)$$

接着，令

$$\begin{aligned} \bar{b}_k &\triangleq \max_{i \leq k} y_i = \max(\bar{b}_{k-1}, y_k) \\ \underline{b}_k &\triangleq \min_{i \leq k} y_i = \min(\underline{b}_{k-1}, y_k). \end{aligned} \quad (4.11)$$

最后基于设计出下面的控制律

$$u_k = \begin{cases} -\hat{\eta}_k + y_{k+1}^* & \text{if } |y_k - y_{i_k}| \leq D \\ -\hat{\eta}_k + \frac{1}{2}(\bar{b}_k + \underline{b}_k) & \text{if } |y_k - y_{i_k}| > D \end{cases} \quad (4.12)$$

这里， D 是一个合适的常数值。

由此看出，最近邻估计可以比较准确地给出一维情形下非参数部分的估计，从而解决半参数系统的自适应控制问题。但是有一定的局限性，主要体现在：

1. 由于最近邻时刻 i_k 的计算需要遍历所有的历史值，因此，随着时间的增长，理论上需要无限的内存用来存储历史数据。这给实施带来了困难。
2. 由于在计算 \hat{g}_k 时没有对干扰值作特别处理，因此适用于干扰值的有界范围比较小且变化比较慢的系统。

3. 没有充分利用历史数据和关联先验信息，只是利用最近邻时刻的数据，计算结果不一定是最优的。

以上的缺点存在，导致现有的半参数自适应控制存在很大的局限性。本章借助于其他的非线性辨识算法去设计新的非参数部分的估计算法。

4.2.2 神经网络

机器学习解决的问题从数学上主要分为分类和回归。其中分类处理的数据主要是离散型数据，回归解决的对象和思路跟控制中的估计、预测十分类似。而神经网络作为一种十分有效的回归与预测算法，在非线性辨识中应用十分广泛。神经网络主要由输入层、隐含层和输出层组成（最简单的神经网络可能没有隐含层），依据不同的激活函数或者不同的学习算法，种类十分丰富。

本章以及本文主要讨论一种十分常见的单隐层前馈神经网络（Single hidden layer feedforward network, SLFN），即具有一个输入层、一个隐含层以及一个输出层的前馈型神经网络。这是一种多层网络，其中输入层神经元接受外界输入，隐含层与输出层的神经元对信号进行加工，最终结果由输出层神经元输出。

下面首先阐述神经网络的基本数学模型。对于一个具有 N_i 个输入神经元、 N_o 个输出神经元以及 N_h 个隐含层神经元的单隐层前馈神经网络来说，如果其激活函数为 $g(\cdot)$ ，并存在 N_s 个输入输出样本对

$$\{\mathbf{x}_j, \mathbf{t}_j\}, j = 1, 2, \dots, N_s$$

这里，输入向量为

$$\mathbf{x}_j = [x_{j,1}, x_{j,2}, \dots, x_{j,N_i}]^T \in \mathcal{R}^{N_i}$$

期望的输出向量为

$$\mathbf{t}_j = [t_{j,1}, t_{j,2}, \dots, t_{j,N_o}]^T \in \mathcal{R}^{N_o}$$

则对于任意输入向量 \mathbf{x}_j ，第 l 个 ($l = 1, 2, \dots, N_o$) 输出层神经元的输出为

$$\begin{aligned} o_{j,l} &= \sum_{i=1}^{N_h} \beta_{i,l} g(\mathbf{w}_i, b_i, \mathbf{x}_j) \\ &= \sum_{i=1}^{N_h} \beta_{i,l} h(\mathbf{x}_i) \\ &= \mathbf{h}(\mathbf{x}_j)^\tau \cdot \boldsymbol{\beta}_l \end{aligned} \quad (4.13)$$

其中， \mathbf{w}_i 和 b_i 分别是连接第 i 个隐层神经元与输入层的权重向量和阈值， $\boldsymbol{\beta}_l$ 是连接 l 个输出层神经元和隐含层的权重， $\mathbf{h}(\mathbf{x}_j)$ 为隐含层的输出向量。

一般来说，同一层的激活函数是一致的。如果第 i 个隐含神经元的激活函数 $g(\cdot)$ 是加性的 (addictive)，比如 Sigmoid 型或者正弦型，则其输出为

$$g(\mathbf{w}_i, b_i, \mathbf{x}_j) = g(\mathbf{w}_i^\tau \cdot \mathbf{x}_j + b_i) \quad (4.14)$$

如果是径向基 (Radial base function, RBF) 网络，则

$$g(\mathbf{w}_i, b_i, \mathbf{x}_j) = g(b_i \|\mathbf{x}_j - \mathbf{w}_i\|) \quad (4.15)$$

此时， g 是某种径向对称的标量函数，通常定义为关于样本到数据中心 \mathbf{w}_i 之间的欧氏距离的单调函数，比如高斯径向基函数等。这样，在命名上， \mathbf{w}_i 和 b_i 一般不称为隐层的权重和阈值，而是激活函数的中心 (center) 和影响因子 (impact factor)。

理论上，对于给定的样本数据集，上述定义的具有 N_h 个隐含层神经元和激活函数为 $g(\cdot)$ 的 SLFN，具有零误差逼近 N_s 个样本的性质，即

$$\sum_{j=1}^{N_h} \|o_j - t_j\| = 0, \quad j = 1, 2, \dots, N_s$$

这意味着，存在一组 \mathbf{w}_i 、 b_i 和 $\boldsymbol{\beta}$ ，使得

$$\mathbf{h}(\mathbf{x}_j) \boldsymbol{\beta} = t_j, \quad j = 1, 2, \dots, N_s \quad (4.16)$$

将上面 N_s 个方程堆积起来，写成紧凑的矩阵形式就是

$$\mathbf{H}\boldsymbol{\beta} = \mathbf{T} \quad (4.17)$$

其中， \mathbf{H} 是隐含层的输出矩阵，具体为

$$\mathbf{H}(\mathbf{w}_1, \dots, \mathbf{w}_{N_h}; b_1, \dots, b_{N_h}; \mathbf{x}_1, \dots, \mathbf{x}_{N_s}) = \begin{bmatrix} h(\mathbf{w}_1, b_1, \mathbf{x}_1) & \cdots & h(\mathbf{w}_{N_h}, b_{N_h}, \mathbf{x}_{N_1}) \\ \vdots & \cdots & \vdots \\ h(\mathbf{w}_1, b_1, \mathbf{x}_{N_s}) & \cdots & h(\mathbf{w}_{N_h}, b_{N_h}, \mathbf{x}_{N_s}) \end{bmatrix}_{N_s \times N_h} \quad (4.18)$$

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_1^\tau \\ \vdots \\ \beta_{N_h}^\tau \end{bmatrix}_{N_h \times N_o} \quad (4.19)$$

且

$$\mathbf{T} = \begin{bmatrix} \mathbf{t}_1^\tau \\ \vdots \\ \mathbf{t}_{N_h}^\tau \end{bmatrix}_{N_s \times N_o} \quad (4.20)$$

如果隐含层神经元个数等于样本的个数，即 $N_s = N_h$ ，那么矩阵 \mathbf{H} 是方阵且可逆的，则 SLFN 可以实现零误差逼近的结果。然而，在实际的大多数情况下，隐含层神经元个数远小于样本个数，即 $N_h \ll N_s$ 。这样， \mathbf{H} 不是一个方阵，就不存在准确的一组 \mathbf{w}_i 、 b_i 和 $\boldsymbol{\beta}$ ，使得 $\mathbf{H}\boldsymbol{\beta} = \mathbf{T}$ 精确成立。这种情况下，神经网络学习的目标就是寻找合适的一组 $\hat{\mathbf{w}}_i$ 、 \hat{b}_i 和 $\hat{\boldsymbol{\beta}}$ ，使得

$$\begin{aligned} & \|\mathbf{H}(\hat{\mathbf{w}}_1, \dots, \hat{\mathbf{w}}_{N_h}; \hat{b}_1, \dots, \hat{b}_{N_h})\hat{\boldsymbol{\beta}} - \mathbf{T}\| = \\ & \min_{\hat{\mathbf{w}}_i, \hat{b}_i, \hat{\boldsymbol{\beta}}} \|\mathbf{H}(\mathbf{w}_1, \dots, \mathbf{w}_{N_h}; b_1, \dots, b_{N_h}) - \mathbf{T}\| \end{aligned} \quad (4.21)$$

成立，等价于最小化下面这个基于累计误差的损失函数

$$E = \sum_{j=1}^{N_s} (\mathbf{h}(x_j)\boldsymbol{\beta} - \mathbf{t}_j)^2. \quad (4.22)$$

多层网络的学习能力依赖于强大的学习算法，误差反向传播（error BackPropagation, BP）是一种十分经典的代表。迄今为止，现实中的神经网络都是使用 BP 算法进行训练，不仅仅局限于多层前馈神经网络，还适用于递归神经网络等其它类型。BP 算法是一种基于梯度下降（gradient-descent-based）的学习算法。将需要调整的权重 w_j 和 β 以及阈值 b_j 等网络参数，整体记作向量 \mathbf{W} ，则 BP 算法按照下面的式子调整 \mathbf{W} ：

$$\mathbf{W}_k = \mathbf{W}_{k-1} - \eta \frac{\partial E(\mathbf{W})}{\partial \mathbf{W}}, \quad (4.23)$$

其中， η 是学习速率。

算法 4.1. BP 学习算法的主要流程

输入：训练样本集 $\{\mathbf{x}_j, \mathbf{t}_j\}$, $j = 1, 2, \dots, N_s$ ；

学习速率 η ；

迭代次数上限 N_{max}

初始化所有网络参数（随机选择，或者根据经验指定）

for $m = 1$ to N_{max} **do**

 根据输入样本和当前参数计算所有样本的输出结果；

 计算输出层的累计误差；

 将误差逆向传递至隐层神经元，根据隐层神经元的误差来对连接权重和阈值进行调整；

 根据方程(4.23)更新 \mathbf{W} ；

 判断累积误差是否达到停止条件，如果达到，则退出当前循环；否则，继续当前迭代过程；

end for

输出：网络参数向量 \mathbf{W} 确定的前馈型神经网络

在前馈型神经网络中，BP 算法的主要工作流程见算法(4.1)。从学习过程可以看出，BP 算法存在如下问题：

1. 学习速率 η 的大小会影响算法的迭代过程，主要表现在，如果 η 太大，则算法会变得不稳定且可能会发散；如果 η 太小，则收敛速度非常慢。
2. 本质上是基于梯度的搜索寻优方法，会陷入局部最优的困境，即网络参数的更新会收敛到某个误差局部最小的情况，这是梯度下降所导致的。

3. 神经网络可能存在过度训练、过度拟合的情形，以致于网络的泛化能力很差。
4. 从初始解出发，迭代寻找最优参数值，其过程通常非常耗时，难以做到实时在线计算。

以上这些因素对于神经网络在控制系统中的应用带来了很多问题，前面三条包括学习速率、局部最优、过度训练的问题有一些方法去改进，但是第四条迭代过程耗时这个问题是由梯度算法本身的特性所决定，难以从根本上解决。这就导致了超限学习机的提出。

4.2.3 ELM 及其变体

传统上对于神经网络的理解，都认为需要网络的学习过程需要调整所有的参数。但实际上，如果输入层到隐含层的权重和阈值不变，那么隐含层的输出矩阵 \mathbf{H} 就保持不变，仅调整隐含层到输出层的权值就可以改变整个网络的最终输出。超限学习机就是利用这个思路建立起来的，用来解决传统基于梯度学习算法的耗时训练的缺点。

超限学习机的基本算法主要包括三个步骤，针对单隐层前馈神经网络的学习过程见算法4.2。

算法 4.2. ELM 算法

输入: 训练样本集 $\{\mathbf{x}_j, \mathbf{t}_j\}$, $j = 1, 2, \dots, N_s$

Step1: 随机初始化输入权重 \mathbf{w}_i 和阈值 b_i 参数

Step2: 计算隐含层输出矩阵 \mathbf{H} ，见表达式(4.18)

Step3: 计算输出层权重向量 β ，根据如下表达式

$$\beta = \mathbf{H}^\dagger \mathbf{T} \quad (4.24)$$

其中 \mathbf{H} 、 \mathbf{T} 和 β 的定义分别见方程(4.18)、(4.20)和(4.19)，而 \mathbf{H}^\dagger 代表了矩阵 \mathbf{H} 的 Moore-Penrose 广义逆。

输出: 网络参数向量 \mathbf{W} 确定的前馈型神经网络

图(4.1)表示的是 ELM 在单隐层神经网络学习过程中的主要计算步骤。实际上，(4.24)计算的是方程(4.17)的最小二乘解（通常也是最小范数解），即

$$\beta = (\mathbf{H}^\top \mathbf{H})^{-1} \mathbf{H}^\top \mathbf{T} \quad (4.25)$$




图 4.1 超限学习机的网络结构（单隐层前馈型）和算法流程

由于没有迭代过程，因此 ELM 在解决分类或者回归等问题时学习时间很短，主要耗时在矩阵的加减乘除和求逆运算的时间。从学习过程可以看出，ELM 的求解思路和最优化方法以及最小二乘辨识算法有些相似，因此基本算法存在的问题和改进思路也类似。上述算法 4.2 介绍的是原始 ELM 的批处理形式，由于实际中样本可能不是一次性获得的，因此和最小二乘算法一样，得到 ELM 的递推形式，即在线序列 ELM 算法（OS-ELM）^[29]。

OS-ELM 的推导过程不再详细介绍，和 RLS 类似。OS-ELM 对于控制系统的辨识十分有用，因为控制系统的参数大多是实时产生的，需要在线辨识。然而 OS-ELM 和批处理形式最后的效果是一致的，只是中间过程不一样，并没有对网络结构和目标函数进行优化。基本 ELM 优化的仅仅是经验损失风险，目标函数见(4.22)，因此 ELM 和 OS-ELM 都可能存在泛化能力不足和过拟合的现象。为了解决这个问题，相关学者^[41, 42]提出了正则化 ELM（简称 Re-ELM）和正则化 OS-ELM（简称 ReOS-ELM）。

神经网络在人工智能领域一直发挥重大作用，而人工智能的发展也一直推动着神经网络的研究。为了更好地利用神经网络实现预测和分类，特别是 2012 年之后，深度学习（Deep Learning, DL），借助于大量数据的驱动，在图像分类、语音识别、自然语言处理等应用领域中获得了巨大成功^[43]。目前大部分深度学习算法大部分是基于神经网络建立。对于深度学习来说，隐含层的数量级为十几层到几百层不等，甚至上千层。深层网络结构和特征学习思想是深度学习的两大主要特点。针对大数据的应用，超限学习机也有相关变体，如 H-ELM（High-Performance Extreme Learning Machine）^[44]与深度学习相比。超限学习机在不丢失精度的条件下具有快速的优势，比较见表 4.1 所示。可以看出，超限学习机不管是在一般量级的数据样本和大数据学习应用领域都具有很大的潜力。

表 4.1 超限学习机与常见深度学习算法的性能比较

算法名称	测试精度 (%)	训练时间
H-ELM	99.14	281.37s
Multi-layer ELM	99.03 ± 0.04	281.37s
Deep Belief Networks(DBN)	98.87	20580s(5.7 hours)
Deep Boltzmann Machine(DBM)	99.05	68246s(19 hours)
Stacked Auto Encoders(SAE)	98.6	>17 hours
Stacked Denoising AutoEncodes(SDAE)	98.72	>17 hours

4.2.4 ELM 估计

基于机器学习的辨识与建模是数据驱动的，可以适用于线性和非线性系统，主要建立系统的输入输出模型。快速、高精度的特点使得 ELM 迅速称为系统与控制领域很好的建模、估计与预测算法^[45]。特别是经过优化、提高泛化等方面性能的 ELM 变体算法，如 Re-OSELM。不同于(4.22)和(4.21)，ReOS-ELM 最小化目标的损失函数是

$$\|H\beta - T\|^2 + \lambda\|\beta\|^2 \quad (4.26)$$

正则化因子 λ 的引入提高了网络的泛化能力。图(4.2)展示了用 Re-OSELM 建立非线性模型的框图。

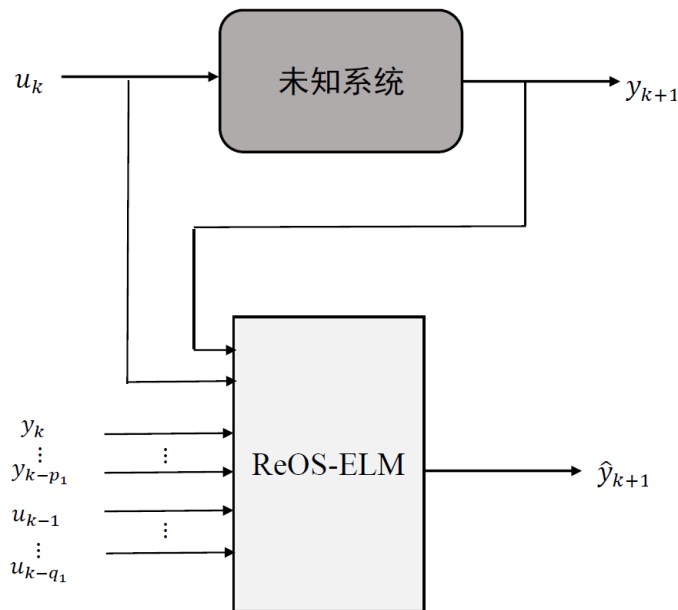


图 4.2 Re-OSELM 算法的建模示意框图

类似于 RLS，OS-ELM 和 Re-OSELM 等算法在系统建模与估计过程一般都是分

为两个阶段。第一个阶段是初始化网络参数和输出权重 β 估计值。对于 Re-OSELM 来说，需要一部分的离线输入输出数据用来完成初始化阶段，通过网络得出 H_0 和 T_0 之后，需要计算

$$\begin{aligned} P_0 &= (H_0^T H_0 + \lambda I_{N_h})^{-1} \\ \beta^0 &= P_0 H_0 T_0 \end{aligned} \quad (4.27)$$

这里， I_{N_h} 是 $N_h \times N_h$ 的单位矩阵

在 Re-OSELM 算法更新权重的过程中引入恰当的或者自适应的遗忘因子 ρ ，可以使得算法能够应用到时变参数系统中。由于正则化因子 λ 的存在，即使不需要大于隐含层个数的样本数据用来初始化 β^0 ，初始小规模训练集也是不可少的。然而，在控制系统中，由于输出值跟实际输入密切相关，因此一定数量的离线输入输出数据一般情况下是难以获得的，这就限制了 Re-OSELM 在实际控制系统中的应用。

ITF-OELM 算法就是用来解决缺少离线初始化数据问题而提出的。ITF-OELM 算法主要针对下面的单输入单输出离散时间非线性系统

$$y_{k+1} = g(\mathbf{x}_k) + \phi(\mathbf{x}_k)u_k \quad (4.28)$$

这里 \mathbf{x}_k 是由 $\{u_k, y_k\}$ 组成的回归向量， $g(\cdot)$ 和 $\phi(\cdot)$ 是具有未知参数的未知非线性函数。用 ITF-OELM 算法分别估计 $g(\cdot)$ 和 $\phi(\cdot)$ ，得到 $\hat{g}(\cdot)$ 和 $\hat{\phi}(\cdot)$ ，那么基于 ITF-OELM 估计的自适应控制律为

$$u_k = \frac{y_{k+1}^* - \hat{g}(\mathbf{x}_k)}{\hat{\phi}(\mathbf{x}_k)} \quad (4.29)$$

这里， y_{k+1}^* 是期望的输出值。

基于 ITF-OELM 的自适应控制框图如图4.3所示。ITF-OELM 算法与 Re-OSELM 的不同点主要在于初始化输出权重的过程。前者不需要一定数量的离线数据，仅仅用第一组到达的数据初始化估计。另外，ITF-OELM 还引入了再学习机制，即如果发现估计偏差较大，就重新初始化网络的所有参数，重新学习。这样，ITF-OELM 可以应用于快时变系统，且不需要过多的离线数据。

下面借助 ITF-OELM 来解决本课题的非参数部分的估计问题。首先要确定的是




图 4.3 基于 ITF-OELM 的自适应控制框图

网络的输入输出样本数据。本文要估计的非线性部分为

$$z_k = f(\psi_k) + \epsilon_{k+1} \quad (4.30)$$

因此，神经网络的输入是 $d_2 = p_2 + q_2$ 维向量

$$\psi_k = [y_k, y_{k-1}, \dots, y_{k-p_2}, u_{k-1}, \dots, u_{k-q_2+1}]^T$$

d_2 的具体数值视实际被控对象而定。输出是标量 z_k 。因此网络的输出层只有一个神经元，输入层含 d_2 个神经元。

本课题针对半参数系统在原始的 ITF-OELM 算法基础上做了几点变化。首先是估计的非线性函数只有一个，其次是在学习机制的不同。训练网络采用的输入数据 ψ_k 直接来源于输入和观测到的历史输出数据，然而输出样本数据为

$$\hat{z}_{k-1} = y_k - \phi_k^T \hat{\theta}_{k-1} - u_{k-1} \quad (4.31)$$

这个非线性估计部分是除去参数估计之后的剩余部分。用基于单隐层网络的 ELM 学习算法得到的估计值是

$$\check{z}_k = H_k \beta^k \quad (4.32)$$

和其他监督学习算法一样，网络的训练结果依赖于样本数据的准确性。 \hat{z}_{k-1} 的值依赖于参数估计值 $\hat{\theta}$ ，因此当参数估计值趋于稳定或者参数集合收敛到一定范围之后，需要重新初始化网络参数，继续辨识。也就是说，本课题在实施 ITF-OELM 算法时，

不直接采用原本的再学习机制，而是引入另外一种情况下的再学习机制。这样就可以做到非参数估计更加准确。

本课题基于 ELM 算法估计非参数部分的实施过程依赖和控制密切相关，故具体算法公式将和自适应控制器设计一起在下一节介绍。

4.3 自适应控制器




图 4.4 半参数自适应控制系统中采用的单隐层前馈网络结构和参数

4.3.1 算法设计

用信息浓缩估计参数部分，用 ELM 估计非参数部分，如图4.4。在前面两种算法的基础上，可以设计出半参数自适应控制器^[46]，主要包含两个过程，即初始化阶段和自适应控制阶段。在初始化阶段，需要完成信息浓缩估计器关联先验信息设置相关参数集的任务，以及 ELM 学习算法的网络参数初始化任务；自适应控制阶段前半段主要是参数估计，后半段主要是神经网络的学习更新非参数部分的估计，从而产生合适的控制输入，完成轨迹跟踪任务。

控制的目标是使得系统4.1跟踪上期望的轨迹 y_k^* , $k \geq 0$ 。下面介绍具体实施流程，其中信息浓缩估计部分直接针对二维参数情形设计。

1. 初始化阶段

(a) 设置 $k = 0$ ，系统的初始状态为

$$\phi_0 = [y_0, y_{-1}]^\tau$$

$$\psi_0 = [y_0, \dots, y_{-p_2}, u_{-1}, \dots, u_{-q_2+1}]$$

(b) 根据关于 θ 的先验信息可以得到初始的多边形为 Γ_0 (通常是四边形)，以及初始的参数估计 $\hat{\theta}_0$.

(c) 定义 SLFN 网络的隐含层神经元个数 N_h ，正则化因子 λ 和遗忘因子 ρ .

(d) 对于第 i 个隐层神经元，随机初始化网络参数 (a_i, b_i) ， $i = 1, 2, \dots, N_h$.

(e) 设置 β^0 和 P_0 为

$$\begin{aligned} P_0 &= (\lambda \mathbf{I}_{N_h})^{-1} \\ \beta^0 &= \mathbf{0}_{N_h} \end{aligned} \quad (4.33)$$

这里， \mathbf{I}_{N_h} 和 $\mathbf{0}_{N_h}$ 分别记作 $N_h \times N_h$ 的单位矩阵和 $N_h \times 1$ 的零向量。

(f) 设置再学习机制参数。让 $\sigma_k = \text{var}(C_k)$ 代表在多边形区域 C_k 的所有顶点坐标的方差，即

$$\begin{aligned} \sigma_{n_k}(1) &= \text{var}(X_{P_1}, X_{P_2}, \dots, X_{P_{n_k}}) \\ \sigma_{n_k}(2) &= \text{var}(Y_{P_1}, Y_{P_2}, \dots, Y_{P_{n_k}}) \end{aligned} \quad (4.34)$$

(g) 设置 $Flag = 0$ ，意味着尚未激活再学习过程，并记 δ 为学习方差的上限。

(h) 随机产生一个有界的控制输入 u_0 ，并发送给控制系统(4.1)；设置 $k = 1$ ，然后转到 Step 2(a).

2. 自适应控制阶段

(a) 获得系统在第 k 个时刻的输出值 y_k ，并利用第二章的公式(??)计算 $v_{k,1}$ 和 $v_{k,2}$.

(b) 用第三章的公式得到当前的多边形区域 C_k ，并将 C_k 的中心作为当前参数估计值 $\hat{\theta}_k$.

(c) 计算 σ_k , 如果 $Flag = 0 \wedge \sigma_k(1) \leq \delta \wedge \sigma_{n_k}(2) \leq \delta$ 那么设置 $\gamma = 1$ 与 $Flag = 1$ 。

(d) 设置 $\hat{z}_{k-1} = y_k - \phi_{k-1}^T \hat{\theta}_k - u_{k-1}$ 。

(e) 如果 $\gamma = 1$ 那么执行 (i); 否则, 执行 (ii)。

i. **Updating:** 将 $(\psi_{k-1}, \hat{z}_{k-1})$ 作为 SLFN 的输入输出样本数据, 计算网络的隐含层输出 H_{k-1} , 并使用下面的等式计算矩阵 P_k 和隐含层到输出层的权重

$$\begin{aligned} P_k &= \frac{1}{\rho} (P_{k-1} - P_{k-1} H_{k-1}^T (\rho \\ &\quad + H_{k-1} P_{k-1} H_{k-1}^T)^{-1} H_{k-1} P_{k-1}) \\ \beta^k &= \beta^{k-1} + P_{k-1} H_{k-1}^T (\hat{z}_{k-1} - H_{k-1} \beta^{k-1}) \end{aligned} \quad (4.35)$$

ii. **Relearning:** 执行在初始化阶段的步骤 1-(c), 1-(d), 1-(e)。

(f) 将 ψ_k 作为 SLFN 的输入向量, 并计算隐含层的输出矩阵 H_k , 从而得到非参数的估计

$$\check{z}_k = H_k \beta^k \quad (4.36)$$

(g) 结合参数和非参数两部分的估计, 根据必然等价原理设计控制输入为

$$u_k = y_{k+1}^* - \phi_k^T \hat{\theta}_k - \check{z}_k \quad (4.37)$$

(h) 设置 $k = k + 1$, 然后转到 Step 2(a)。

4.3.2 稳定性分析

下面针对系统 4.1 和半参数自适应控制算法分析闭环特性。系统在 $k + 1$ 时刻的期望输出为 y_{k+1}^* , 实际输出值为 y_{k+1} , 则跟踪误差定义为

$$e_{k+1} = y_{k+1} - y_{k+1}^* \quad (4.38)$$

从方程(4.1), (4.31)和(4.37), 容易得到

$$\begin{aligned}
 e_{k+1} &= y_{k+1} - y_{k+1}^* \\
 &= y_{k+1} - \hat{y}_{k+1} + \hat{y}_{k+1} - y_{k+1}^* \\
 &= (y_{k+1} - \phi_k^\tau \hat{\theta}_k - \check{z}_k - u_k) + (\phi_k^\tau \hat{\theta}_k + \check{z}_k + u_k - y_{k+1}^*) \\
 &= \phi_k \theta_k + z_k - \phi_k^\tau \hat{\theta}_k - \check{z}_k \\
 &= \phi_k (\theta_k - \hat{\theta}_k) + (z_k - \check{z}_k) \\
 &= \phi_k \tilde{\theta}_k + \tilde{z}_k
 \end{aligned} \tag{4.39}$$

从上面的方程(4.39)可以看出, 如果参数部分和非参数部分的估计误差 $\tilde{\theta}_k$ 和 \tilde{z}_k 收敛到零, 那么跟踪误差 e_{k+1} 也收敛到零。前面一章设计的信息浓缩估计可以保证未知参数估计收敛到零, 并且本章的 ELM 估计非参数部分也可以保证收敛性, 因此, 本章设计的半参数自适应控制器可以保证渐进稳定性。

4.4 仿真实例

4.4.1 仿真环境

本章验证自适应控制器的性能, 选择仿真如下半参数被控对象

$$y_{k+1} = \theta_1 y_k + \theta_2 y_{k-1} + u_k + f(y_k, y_{k-1}) + \epsilon_{k+1} \tag{4.40}$$

其中, 系统的未知参数和未知函数设定为

$$\begin{aligned}
 \theta_1 &= -1, \theta_2 = 1 \\
 f(y_k, y_{k-1}) &= \sin(y_k^2) + \cos(y_{k-1})
 \end{aligned} \tag{4.41}$$

同时, 未知的噪声序列是独立同分布 (i.i.d) 的随机有界均匀分布, 取自 $U(-0.1, 0.1)$ 。该被控对象的参数部分是二维情形, 非参数部分也是二维情形, 即 $p_1 = 2$ 同时 $q_2 = 2$ 。

系统可利用的先验信息在数学上描述为

$$\begin{aligned}
 \underline{f}(\psi_k) &= -3, \bar{f}(\psi_k) = 4 \\
 \underline{\epsilon} &= -0.1, \bar{\epsilon} = 0.1 \\
 \underline{\theta}_1 &= -10, \bar{\theta}_1 = 10 \\
 \underline{\theta}_2 &= -10, \bar{\theta}_2 = 15
 \end{aligned} \tag{4.42}$$

为了更好的验证半参数自适应控制器的性能，本章选取了经典的自适应控制算法，即自校正控制器（STR）作为对比算法。自校正控制器（或者自校正调节器）采用最小二乘算法（RLS）估计未知参数。不过由于 RLS 针对的是线性系统，而本章要控制的对象是(4.40)是非线性的。对比仿真实验的唯一控制变量在于自适应控制算法，因此先验信息(4.42)对于 STR 同样可以利用，需要对原生的 RLS 估计进行简单的改进，补偿掉非线性部分。

对比方法 RLS 实际估计的线性部分为

$$L_k \triangleq \theta_1 y_k + \theta_2 y_{k-1} = y_{k+1} - u_k - \hat{z}_{RLS} \tag{4.43}$$

其中， \hat{z}_{RLS} 是 STR 实施过程中对非线性部分的一个粗略估计，用来补偿掉非线性部分，具体值可取

$$\hat{z}_{RLS} = \frac{1}{2}(\underline{f}(\psi_k) + \bar{f}(\psi_k)) \tag{4.44}$$

RLS 估计算法也包括两个过程，第一个是初始化过程确定初始值，即

$$\begin{aligned}
 \boldsymbol{\pi}_0 &= \alpha \boldsymbol{I}_{d_1} \\
 \boldsymbol{\theta}^0 &= [0.1, \dots, 0.1]^\tau
 \end{aligned} \tag{4.45}$$

α 取较大的数（一般为 10^4 到 10^8 之间）。第二阶段是递推过程，每一步都会改变 $\boldsymbol{\theta}$ 和 $\boldsymbol{\pi}^0$ 的值。第 k 时刻的估计为

$$\begin{aligned}
 \hat{\boldsymbol{\theta}}_k &= \hat{\boldsymbol{\theta}}_{k-1} + \zeta_k \boldsymbol{\pi}_{k-1} \boldsymbol{\phi}_k (L_k - \boldsymbol{\phi}_k^\tau \hat{\boldsymbol{\theta}}_{k-1}) \\
 \zeta_k &= (1 + \boldsymbol{\phi}_k^\tau \boldsymbol{\pi}_{k-1} \boldsymbol{\phi}_k)^{-1} \\
 \boldsymbol{\pi}_k &= \boldsymbol{\pi}_{k-1} - \zeta_k \boldsymbol{\pi}_{k-1} \boldsymbol{\phi}_k \boldsymbol{\phi}_k^\tau \boldsymbol{\pi}_{k-1}
 \end{aligned} \tag{4.46}$$

方程(4.44)到(4.46)就是本章对比仿真采用的 RLS 算法。

4.4.2 仿真结果

设定的期望跟踪信号为

$$y_k^* = 1.5 \sin(2\pi k \times T_s) \quad (4.47)$$

其中，控制周期为 $T_s = 0.01s$ 。仿真半参数自适应控制和自校正控制算法，得到系统的输出曲线分别为4.5和4.7。在图4.5中，可以看出半参数自适应控制的轨迹跟踪精度比较好，系统的实际输出很快的跟踪上了期望的输出，误差逐渐收敛到一个很小的范围。相反，自校正控制的跟踪效果就较差，经过一段时间后，系统的实际输出和期望值偏差仍然较大，如图4.7所示。在本节的仿真实例中，自适应控制的输出跟踪误差在自校正控制的基础上减少了大约 10 倍。






图 4.5 系统输出结果：半参数自适应控制算法

造成跟踪控制效果较大差异的重要原因之一，就是两种控制算法中对系统参数估计算法的不同，图4.7展示了仿真得到的参数估计曲线。相对于图4.7(b)中改进的最小二乘算法来说，图4.7(a)的信息浓缩估计参数估计比较准确。

除了对系统参数不确定性的处理外，半参数自适应控制中用在线超限学习机估计非参数部分，估计结果如图5.4(a)，选择了径向基函数作为激活函数，网络的隐含层



(a) 输出轨迹




(b) 跟踪误差

图 4.6 系统输出结果：自校正控制算法


个数在 10 到 20 之间。从图中可以，对非线性函数的逼近结果很好，导致对下个周期的非参数部分估计比较准确。这充分说明了引入超限学习机这种机器学习算法大大减少系统的非参数不确定性，从而能够计算出合适的控制输入，给到被控对象。另外，基于超限学习机的网络学习过程也没有影响控制的实时性，计算很快，在普通 PC 机上（实验计算机配置为 Intel i5 处理器，主频为 2.3GHz）每个周期的估计时间在 0.05 毫秒以内，如果系统经过裁剪和优化可进一步提高运算速度，基本能够满足基于工业 PC 的控制系统对实时性的要求。网络学习过程并没有引入一般深度网络依赖的并行计算等复杂设计，有利于在工业嵌入式系统中实现。

4.5 本章总结

本章主要设计了基于超限学习机的非线性估计和半参数自适应控制。首先给出了半参数系统的轨迹跟踪问题的数学描述，并分析了半参数模型的自适应估计和控制问题；然后介绍了超限学习机的主要思想、算法特点和改进算法，并用合适的超限学习机变体算法设计了非参数部分的估计算法；接着在信息浓缩和超限学习机的自适应估



(a) 信息浓缩估计



(b) 改进的最小二乘估计

图 4.7 未知参数估计结果对比




图 4.8 半参数自适应控制中超限学习机对非参数部分的估计结果

计基础上，设计了针对半参数系统轨迹跟踪问题的自适应控制器，并分析了闭环跟踪稳定性；最后用仿真实例测试和验证本章设计的半参数自适应控制算法的性能，用改进的自校正控制算法作对比。

第 5 章 半参数自适应运动控制

反馈控制是为了解决实际问题而研究设计的。前面几章针对一种典型先验信息和数学描述的模型设计了半参数自适应估计与控制器，并用数值仿真验证了控制器性能。本章将考虑半参数自适应控制引入到运动控制场景，解决多关节机械臂中伺服电机的控制问题。

5.1 问题描述

5.1.1 机器人控制

21 世纪以来，机器人技术被认为是对未来新兴产业发展具有重要意义的高技术之一。一般来说，机器人是一个复杂的多输入、多输出非线性系统，具有时变、强耦合和非线性的动力学特征^[47]。机器人运动学和动力学的非线性和耦合性使得机器人控制系统的设计十分复杂。一般来说，将如图 5.1 所示机器人（机械臂）的运动控制分成两个阶段分别优化，即任务空间的轨迹（路径）规划和关节空间的跟踪控制^[48]。前者轨迹（路径）规划部分性能的提高涉及到运动学甚至障碍物约束等多种综合因素的考量，轨迹规划器最终会以关节空间形式给后者（跟踪控制器）提供一段期望的轨迹。本章主要考虑关节空间的跟踪控制问题。



图 5.1 一种模块化、多关节、协作型的机器人

工程应用中由于建模和测量的不准确，加上负载的变化以及外部扰动的影响，实

实际上难以获得机器人精确完整的运动学模型^[49]。因此机器人的控制系统中存在的确定性因素主要可以分为两类，第一类是参数不确定性，如负载质量、连杆长度、连杆质心等物理量全部或部分未知；第二类是非参数不确定性，如高频未建模动态，包括驱动器动力学、结构共振模式，以及低频难以建模动态，如动态/静态摩擦力、关节柔性等。

工业应用的机器人大多具有六个自由度，如图5.1是自主研发的模块化、多关节、协作型机器人，分别由六个关节 J1 到 J6 的执行机构实现。在无障碍情形下，理论上该机器人的末端可以实现空间任意的位姿，其精度主要表现在任务空间（某个笛卡尔空间）的定位精度。工业高性能的应用场合中，一般要求机器人能达到毫米级的定位精度。机器人的位置控制问题最终要驱动各个关节的电机运动，然后经过减速器等传动机构来实现，伺服电机的运动控制与定位精度是影响机器人末端定位精度的关键因素。

5.1.2 伺服电机控制

目前大多数科研、教学和工业应用的机器人都是电力驱动的，一般可分为电压控制和电流控制两种。永磁同步交流伺服电机驱动已成为高性能伺服系统的主要发展方向。对于中小功率型机械臂（比如图5.1所示的协作机器人）的电机建模来说，一般考虑电流控制情形，即电机具有如下的数学模型^[50]：

$$\begin{aligned} i_c &= K_a * u_c \\ \tau &= K_m * i_c \\ J_0 \dot{\omega} + B\omega + \tau_f(\omega) + \tau_l &= K_m K_a u_c \end{aligned} \quad (5.1)$$

其中， Q 、 ω 和 $\dot{\omega}$ 分别是电机输出的角位移（单位是 rad）、角速度（单位是 rad/s），角加速度（rad/s²）； J_0 是折算到电机侧的所有转动惯量之和（包括传动机构和连杆耦合值等，单位是 kg·m²）； B 是粘滞摩擦系数（单位是 N·m·s）， τ_f 是 Coulomb 摩擦力矩（单位是 N·m）； K_a 和 K_m 分别是驱动放大器的导纳系数和电机的力矩常数。

机器人多个关节同时运动时，从单个电机侧感受到的惯量 J_0 是时变的。虽然理论上可以通过机器人的动力学模型计算出关节侧的转动惯量值，但是前面一节介绍的不确定性因素的存在，惯量值的计算常常不准确，并且计算十分耗时。不过，经过减速器的传动，从电机侧感受到的关节侧转动惯量时变的效应减小。以一般机器人最大

功率的第二个关节 J2 为例（减速比 G 一般为 50 到 150 之间），记该轴在机器人动力学模型中惯性矩阵所对应的值为 M_{22} ，则该轴电机侧感受到的所有转动惯量之和为

$$J_0 = J_m + \frac{1}{G^2} M_{22} \quad (5.2)$$

可以看出， M_{22} 的变化效应被缩小了 10^4 的数量级。然而即使这样， J_0 的准取值依然难以获得。

上述伺服电机的控制输入可以认为是给定电压（本质是控制输入电流），被控的输出量是角位移或者速度。由于电机一般都是高转速、低转矩特性，并且安装位置有时和轴不在同一个地方，因此为了让电机真正驱动每个轴的运动，还需要经过减速器、皮带轮等传动机构将转速变小，同时放大转矩。除了转动惯量的不确定性外，受传动机构间隙等因素的影响，后面的摩擦力项也和角速度等具有非线性关系，难以精确建模。如果忽略 Coulomb 摩擦力矩项，借助于拉普拉斯变换，可以得到电机模型(5.1)的传递函数表述式为：

$$\frac{\Omega(s)}{U_c(s)} = \frac{K_m K_a}{J_0 s + B} \quad (5.3)$$

其中 $\Omega(s)$ 和 $U_c(s)$ 分别是时域函数 $\omega(t)$ 和 $u_c(t)$ 的拉普拉斯变换结果。

方程(5.3)是对于速度控制是一阶模型。不过，由于机器人最终控制的是角位移，也就是速度的积分值。因此伺服电机系统可以近似为二阶线性模型，可以采用一些常规的线性控制方法，不过它的参数 J_0 时变， B 常常难以知道精确值。现代伺服系统大都采用数字化离散时间控制。记采样周期为 T_s ，从离散时间控制角度，在第 k 个时刻电机的输入量和输出量分别记为

$$u_k = u_c(k \cdot T_s), \quad y_k = \omega(k \cdot T_s)$$

则系统(5.1)的输入输出关系可以写作

$$y_{k+1} = F(\Psi_k, \epsilon_{k+1}) \quad (5.4)$$

其中 Ψ_k 是输出 y_k 和输入 u_k 的历史数据组成的回归向量， ϵ_{k+1} 是随机干扰。

方程(5.4)综合考虑了 Coulomb 摩擦等所有未建模动态，这样(5.1)转化成离散时间后不确定性大大增加，也就是说电机的离散时间模型本质是非常复杂且难以建立准确

建模的，也就给直接控制系统带来了很大困难。实际上，伺服电机系统可以采用常规的线性系统方法如 PID 控制，可以获得一定的控制效果，但是精度和控制特性都有待提高。这从一个侧面反映了(5.4)的主体是线性的，只是线性部分参数可能未知，并且含有难以建模的非参数部分。另外，伺服电机含有大量可利用的先验信息，如电机转矩的有界性、惯量变化的有界性等。这十分符合本课题前面提出的半参数系统特性。

5.2 控制器设计

基于前面小节的分析，本节将应用半参数模型的理论和方法分析机器人中电机运动控制问题，并设计相应的自适应控制器。

5.2.1 半参数建模

半参数建模的目的在于建立合适的方程（包含线性和非线性部分）去描述实际系统以及蕴含的先验信息。结合方程组(5.1)，电机的角速度 y_{k+1} 主要取决于上一个时刻的角速度 y_k 和加速度 a_k 。如果记 τ_k 、 $\tau_{k,f}$ 分别为电流产生的力矩和电机运动的摩擦阻力（即 $B\omega + \tau_f(\omega)$ ），则电机在 k 时刻的加速度近似为

$$a_k = \frac{(\tau_k - \tau_{k,f} - \tau_l)}{J_0}$$

由速度和加速度的微分关系，可以得到电机的角速度 y_{k+1} 为

$$\begin{aligned} y_{k+1} &= y_k + a_k \cdot T_s + f'(\psi_k) + \epsilon \\ &= \theta_1 \cdot y_k + \theta_2 \cdot u_k + f(\psi_k) + \epsilon_{k+1} \end{aligned} \quad (5.5)$$

其中， θ_1 未知，可以认为近似为 1，而 θ_2 与电机本身参数有关，可以近似为

$$\theta_2 = \frac{K_m K_a}{J_0}$$

$f(\cdot)$ 是未知非线性函数，主要融合了难以建模的摩擦和惯量等信息，而 ϵ_{k+1} 是系的随机干扰。系统的控制输入为电机的电枢电流，即 $u_k = i_c(k \cdot T_s)$ 。

在系统(5.5)中, $\theta = [\theta_1, \theta_2]$ 是系统的参数不确定性部分, 维数

$$d_1 = p_1 + q_1 = 1 + 1 = 2$$

$$\phi_k = [y_k, u_k]$$

参数部分的先验信息表现为有界性。 θ_1 近似为 1, 其先验信息可认为取值在 0.8 到 1.2 之间; θ_1 的上下界可以通过分析电机本身的参数 K_a 、 K_m 的合适范围, 以及在机器人运动过程中惯量 J_0 的变化范围等数值确定大致范围。

$f(\psi_k)$ 是系统的非参数不确定性部分, 回归向量 ψ_k 是历史输入输出数据的组合, 即

$$\psi_k = [y_k, \dots, y_{k-p_2}, u_{k-1}, \dots, u_{k-q_2+1}]$$

维数 $d_2 = p_2 + q_2$ 不定, 对应的是网络的输入层神经元个数, 一般为 1 到 10 之间。一般来说, 维数 d_2 越大, 网络训练的数据越多, 则逼近效果越好; 但同时, 过大的维数也会加重网络训练的计算量, 还会造成过拟合, 实际中可以调整选择合适的维数。

系统的非参数不确定性部分的先验信息也表现为有界性。由于离散时间化导致这里的 $f(\cdot)$ 难以直接找到它的变化范围, 与前面第三章和第四章的上下界函数有所不同。不过, 由于电机本身功率、机械条件和加速度的制约, 电机的速度与前一个时刻相差不会很大, 往往在一定范围内波动, 可以认为 $f(\psi_k)$ 关于回归向量 ψ_k 满足 Lipschitz 条件。具体表现为, 对于两个不同的时刻 k 和 s , $k \neq s$, 存在正常数 $L_{f,1} > 0$ 和 $L_{f,2} > 0$, 使得

$$\begin{aligned} |f(\psi_k) - f(\psi_s)| &\leq \Delta_{k,s} \\ \Delta_{k,s} &= L_{f,1} \cdot \|\psi_{y,k} - \psi_{y,s}\| + L_{f,2} \cdot \|\psi_{u,k} - \psi_{u,s}\| \end{aligned} \quad (5.6)$$

$\|\cdot\|$ 记为向量的某种范数, 一般为欧几里得范数。 $\psi_{y,k}$ 和 $\psi_{u,k}$ 分别是 $f(\cdot)$ 的自变量 ψ_k 中 y_k 和 u_k 的向量部分, 而由于控制输入 u_k 和输出 y_k 可能在数量级上并不匹配, 因此这里分别采用两个常数 $L_{f,1}$ 和 $L_{f,2}$ 来刻画。

一般来说, 随机干扰序列 ϵ_k 也具备有界性且独立同分布, 在电机系统中一般取自某个随机均匀分布。关于随机干扰的先验信息为

$$\underline{\epsilon} \leq \epsilon_k \leq \bar{\epsilon}.$$

5.2.2 自适应估计

为了实现半参数自适应控制,首先得设计自适应估计算法。由于半参数系统(5.5)的参数部分也是二维情形,非参数部分也是有界的,可以利用其先验信息(5.6)借助设计信息浓缩算法估计未知参数。只是有所不同的是,非参数部分的有界形式有所不同,导致算法3.1和方程(2.32)中关于直线的参数 $v_{k,1}$ 和 $v_{k,2}$ 的计算有所不同。下面给出具体推导过程。

当 $k \geq 2$, 对于任意 $0 \leq s \leq k-2$, 由约束关系(5.6)可以得到

$$|f(\boldsymbol{\psi}_{k-1}) - f(\boldsymbol{\psi}_s)| \leq \Delta_{k-1,s} \quad (5.7)$$

而

$$\begin{aligned} |f(\boldsymbol{\psi}_{k-1}) - f(\boldsymbol{\psi}_s)| &= (y_k - \boldsymbol{\theta}^\tau \boldsymbol{\phi}_{k-1}) - (y_{s+1} - \boldsymbol{\theta}^\tau \boldsymbol{\phi}_s) \\ &= (y_k - y_{s+1}) - \boldsymbol{\theta}^\tau (\boldsymbol{\phi}_{k-1} - \boldsymbol{\phi}_s) \end{aligned}$$

再结合(5.7)得到

$$|\boldsymbol{\theta}^\tau (\boldsymbol{\phi}_{k-1} - \boldsymbol{\phi}_s) - (y_k - y_{s+1})| \leq \Delta_{k-1,s} \quad (5.8)$$

因此进一步得到线性约束不等式组

$$(y_k - y_{s+1}) - \Delta_{k-1,s} \leq \boldsymbol{\theta}^\tau (\boldsymbol{\phi}_{k-1} - \boldsymbol{\phi}_s) \leq \Delta_{k-1,s} + (y_k - y_{s+1}) \quad (5.9)$$

在几何上,式子(5.10)就代表了二维空间中两个半平面的约束,作为每个周期的参数信息集 I_k ,可以用来设计信息浓缩估计算法。对于时刻 $k-1$,可以和之前每个时刻比较得出一组类似(5.10)的不等式约束,那么从理论上说存在 $k-2$ 组。但是考虑到计算量的限制,一般情况下,只需要比较相邻两个时刻即可获得比较充分的信息关系,从而在较短时间内获得未知参数比较准确的估计值 $\hat{\boldsymbol{\theta}}$ 。即利用 $s = k-2$ 时的不等式约束

$$(y_k - y_{k-1}) - \Delta_{k-1,k-2} \leq \boldsymbol{\theta}^\tau (\boldsymbol{\phi}_{k-1} - \boldsymbol{\phi}_{k-2}) \leq \Delta_{k-1,k-2} + (y_k - y_{k-1}) \quad (5.10)$$

在获得 θ 的估计值之后，则剩余的非参数部分

$$\hat{z}_k = y_{k+1} - \hat{\theta}^T \phi_{k-1}$$

可以用第四章的基于单隐层神经网络的 ITF-OELM 算法逼近和预测得到 \hat{z}_k 的值。神经网络的输入是包含系统输入和输出历史数据组成的回归向量，实际过程中可以调整相应维度的大小。对于电机模型，一般选择 1-3 个输出和 1-3 个控制输入。选择过多的历史数据，也无太大意义，因为运动角度、角速度一般跟加速度、加加速度（有时称之为冲击）关联度较大。

5.2.3 控制器设计

本章要解决的是机器人运动过程中关节空间的角度跟踪控制问题，从轨迹规划器得到伺服电机转动的角度之后，需要作插补运算可以得到电机在每个周期运动的角度、速度和加速度值。本章针对电机运动的角速度，从离散时间角度针对半参数模型(5.5)设计自适应估计与控制律。在离散时间控制中，控制输入只在每个控制周期改变一次，并且只能采用得到每个周期的系统状态变量和观测值，而实际的被控对象是连续时间的模拟量。

通过相关的轨迹发生器可以得到电机在每个运动周期时刻期望的角度 Q_k^* 、角速度 ω_k^* 和角加速度 $\dot{\omega}_k^*$ 。为了提高伺服电机的定位精度，在电机速度控制的基础上加入位置反馈，将角度跟踪误差作为速度前馈值加入到轨迹规划产生的速度期望值中，即期望的速度跟踪值为

$$y_{k+1}^* = \frac{Q_k^* - Q_k}{T_s} + \omega_{k+1}^*$$

然后对于系统5.5，采用必然等价原理设计的半参数自适应控制律为

$$u_k = \frac{1}{\hat{\theta}_1} (y_{k+1}^* - \hat{\theta}_2 y_k - \hat{z}_k) \quad (5.11)$$

因此，可以得到用半参数自适应控制解决电机伺服控制的总体框图5.2。其中， Q_0 和 Q_d 分别为电机的初始角度值和期望的角度值。




图 5.2 基于超限学习机的半参数自适应控制在电机运动控制中的总体框图

表 5.1 电机相关参数

项目	参数
额定转矩 ($N \cdot m$)	0.64
最大转矩 ($N \cdot m$)	2.23
额定转速 ($r \cdot min^{-1}$)	3000
额定转速 ($r \cdot min^{-1}$)	6500
额定电流 (A)	1.4
最大电流 (A)	4.3
转矩常数 K_m ($Nm \cdot A^{-1}$)	0.4571
电机惯量 ($kg \cdot m^2$)	0.31×10^{-4}
谐波减速比	120

5.3 仿真实例

本节以图5.1所示的机器人第二轴 J2 安装的伺服电机控制为例验证本章设计的半参数自适应运动控制算法的性能。该伺服电机属于日本松下 A6 系列全数字式交流伺服电机，具体型号为 MHMF022L1V2M，是一种小功率的交流同步电机。相关参数如表5.1所示。

设定关节轴 J2 的初始值和期望终值分别为

$$Q_0 = -45^\circ = 0.524rad, Q_d = 85^\circ = 1.484rad$$


经过减速器之后，对应的电机角度的初始值和期望终值分别为（弧度制）

$$Q_0 = -62.88, Q_d = 178.08$$


本章用五次多项式插值作为图5.2的轨迹发生器中的轨迹规划算法，可以做到机器人在关节空间的加速度连续且可导，其导数加加速度（冲击）连续，其轨迹比较平滑^[51]，

一般机器人控制器的关节空间的插补都是采用五次多项式进行。在仿真过程中，可以借助于机器人相关工具箱里提供的函数完成插值规划部分。

目前广泛采用的机器人电机驱动通信总线是工业实时以太网 EtherCAT，其控制周期一般为 0.5ms 到 10ms 之间。为了接近实际情况，本章的电机控制周期取为 $T_s = 1\text{ms}$ 。采用前面设计的半参数自适应控制算法对电机的运动进行轨迹跟踪控制，事先对于电机如表5.1所示准确参数未知，只是知道大致范围，在这种情况下检验控制性能。最终得到电机系统的输出结果为图5.3，以及过程中的控制输入和非线性部分的估计曲线如图5.4所示。轴 2 在运动过程中关节角度的跟踪误差平均值为 0.0021rad。对于如图所示的机器人一般的运动过程中的臂长为 1m，则机器人末端的跟踪误差 $e_{ac} = 0.0021\text{m} = 2.1\text{mm}$ ，跟踪精度在毫米数量级。




(a) 第二轴的关节运动速度曲线（经过减速器之后）




(b) 第二轴的关节角位移曲线（经过减速器之后）

图 5.3 半参数自适应控制算法的系统输出结果，关节角度跟踪误差的平均值为 0.0021rad

另外，采用常规的 PID 算法进行对比仿真，这里采用的调试 PID 参数的策略是在



(a) 第二轴电机系统的非参数部分的估计结果




(b) 第二轴电机系统的控制输入（电机电流）变化曲线

图 5.4 半参数自适应控制算法的运行和估计特性曲线


电机空载或者小负载以及电机名义标称惯量的情况下调试得到满意的性能，然后加上在机器人负载条件下再次测试。最终得到电机系统的输出结果为图5.5(a)，以及过程中的控制输入（电机电流）曲线如图5.6所示。轴 2 在运动过程中关节角度的跟踪误差平均值为 0.0207rad 。对于如图所示的机器人一般的运动过程中的臂长为 1m ，则机器人末端的跟踪误差 $e_{pid} = 0.0207\text{m} = 2.07\text{cm}$ ，跟踪精度在厘米数量级。

对比上面两种控制方法结果，可以得出本课题采用基于超限学习机的半参数自适应控制算法对于解决运动控制问题有如下特点：

1. 基于超限学习机的半参数自适应控制算法提高了系统的跟踪精度，对比常规的 PID 控制精度可以提高大约一个数量级（10 倍）。
2. 基于超限学习机的半参数自适应控制对于系统精度提高主要来源于非参数部分的准确估计，而非参数部分的估计在一定程度上也依赖于参数部分的估计。



(a) 第二轴的关节运动速度曲线（经过减速器之后）



(b) 第二轴的关节角位移曲线（经过减速器之后）

图 5.5 PID 控制算法的系统输出结果，关节角度跟踪误差的平均值为 0.0207rad




图 5.6 PID 控制算法中第二轴电机系统的控制输入（电机电流）变化曲线

3. 半参数自适应估计的准确性导致最终的控制输入有比较好的变化曲线，对比图5.4(b)和5.6容易得出。

5.4 本章总结

本章主要将基于超限学习机的半参数自适应估计与控制应用到运动轨迹跟踪控制中，解决机器人运动中电机的控制问题。首先分析了机器人轨迹跟踪和伺服电机运动控制中多种不确定性存在等控制难点；然后应用本课题提出的半参数系统对单轴伺服电机进行了分析和建模；接着设计了基于超限学习机的半参数自适应估计与控制算法应用单轴伺服电机的控制；最后设计了仿真对比实验测试和验证半参数自适应控制的性能。

结论

系统存在不确定性，一直是控制理论研究和工程应用的难点，特别是在离散时间控制中。本文针对一般同时具有参数和非参数不确定性的离散时间被控对象，在已有半参数理论的基础上，研究并完善半参数建模与分析、估计与控制方法，充分利用了系统的先验信息和输入输出历史数据，提高了离散时间控制的实时性和准确性。本文的主要工作总结如下：

1. 对反馈控制、非线性控制和自适应控制的发展历程、主要趋势和技术特点进行了系统的归纳和总结，指出了最小二乘等线性估计方法的不足，研究了人工神经网络在非线性建模与控制中的应用与难点，介绍了超限学习机，一种在前馈神经网络的实时性应用中具有很大潜力的方法。，针对系统具有参数不确定性和非参数不确定性的特点进行了分析，将系统分为参数描述的线性部分和非参数描述的非线性部分，概括出了一种半参数建模方法，并对实际系统常用的先验信息进行了数学描述。
2. 研究了一种充分利用先验信息的、基于集合的自适应估计方法，即信息浓缩估计，用于解决半参数系统的参数不确定性部分的估计；设计了二维情形下的具体实现算法和步骤，并在数值仿真实验中测试和验证实际效果；归纳总结了信息浓缩估计算法的优缺点，提出了一些计算复杂度问题的优化方向。
3. 介绍了半参数自适应估计与控制问题的一般描述，围绕解决神经网络中经典迭代学习算法的实时性等问题，阐述了超限学习机及其变体的算法特点与非线性建模思路；将超限学习机引入到半参数系统的非参数部分估计中，设计了基于超限学习机的半参数自适应控制算法，并通过仿真实验进行了验证。
4. 在机器人与伺服电机等运动体的轨迹跟踪控制中存在大量的不确定性，将基于信息浓缩估计和超限学习机的半参数建模、估计与控制方法应用到机器人场景中伺服电机的控制问题中，对运动控制问题进行了定制化设计；在仿真实验中进行算法验证，结果表明半参数自适应控制大大提高了轨迹跟踪精度。

基于超限学习机的半参数自适应控制算法的特点主要体现在，充分利用原有系统的先验信息和输入输出历史数据，结合信息浓缩估计和超限学习机等高效且新颖的算

法，其建模与控制思路在解决具有较大不确定性的被控对象时具有一般性与通用性。但是，由于控制中利用的估计算法本身的不足，还有一些问题需要进一步研究与完善：

1. 信息浓缩估计算法的完善。本文目前设计了二维情形下的信息浓缩估计算法，并在自适应运动控制中进行了验证。二维情形可以在一定程度上，解决大量运动控制场景如伺服电机的跟踪控制问题，但是对于涉及到高阶模型，含有多个参数的情况如机器人末端的力反馈控制等问题，可能需要进一步设计高维情形中的信息浓缩估计算法，但核心思路不变。
2. 多变量系统的自适应控制实现。本文主要涉及到控制输入和测量输出都是单一变量的情形，多输入多输出情形的建模与分析思路与本文大致相同，只是涉及到更多变量的信息浓缩估计与神经网络计算，可能需要考虑到本文第三章论述的有关计算复杂度相关的优化策略。

参考文献

- [1] 李阳, 朱家仪, 李树民. 非线性控制理论的回顾与展望 [J]. 飞航导弹, 2004 (11): 55–58.
- [2] Gata K. 现代控制工程 [M]. 4th ed. 北京: 清华大学出版社, 2005.
- [3] 潘胜强. 扰动下线性二次型反馈调节器的鲁棒性与灵敏度 [J]. 控制理论与应用, 1990 (01): 98–104.
- [4] Brasch J, Pearson J. Pole placement using dynamic compensators [J]. IEEE Transactions on Automatic Control, 1970 (15): 34–43.
- [5] 马宏宾, 张星红, 周浩. 例说自适应控制: 从倒立摆谈起 [J]. 系统与控制纵横, 2016, 3 (1): 64–75.
- [6] Ball J A, N C. The sensitivity minimization in an H_{∞} norm: parameterization of all optimal solutions [J]. In: J. Contr, 1987, 46: 785–816.
- [7] Chen H, Guo L. Identification and Stochastic Adaptive Control [M]. 1991.
- [8] 郭雷. 时变随机系统 [M]. 长春: 吉林科学技术出版社, 1992.
- [9] Goodwin G C, Ramadge P J, Caines P E. Discrete-Time Multivariable Adaptive Control [J]. IEEE Transactions on Automatic Control, 1980, 25 (3): 449–456.
- [10] Ma H, Lum K Y. Adaptive Control. InTech [M]. 2009.
- [11] Chen H F, Zhao W X. Recursive identification and parameter estimation [J]. Taylor Francis Usa, 2014.
- [12] 李晓理. 一类离散时间非线性系统的多模型自适应控制 [J]. 控制与决策, 2010 (06): 841–846.
- [13] 侯忠生. 无模型自适应控制的现状与展望 [J]. 控制理论与应用, 2006 (04): 586–592.
- [14] Yang C G, Dai S S, S Ge, Lee T H. Adaptive Asymptotic Tracking Control of a Class of Discrete-Time Nonlinear Systems with Parametric and Nonparametric Uncertainties [C]. In Proceedings of 2009 American Control Conference, St. Louis, USA, June 2009: 580–585.
- [15] 侯忠生. 再论无模型自适应控制 [J]. 系统科学与数学, 2014, 34 (10): 1182–1191.
- [16] Yang C G, Chai T Y, Zhai L F, et al. Semi-parametric Adaptive Control of Discrete-time Nonlinear Systems [C]. In Proceedings of the IEEE International Conference on Automation and Logistics, Shenyang, 2009.
- [17] Xie L L, Guo L. Fundamental Limitations of Discrete-Time Adaptive Nonlinear Control [J]. IEEE Transactions on Automatic Control, 1999, 44 (9): 1777–1782.
- [18] Anonymous. Machine Learning [J]. Technology Review, 2014, 117 (6): 9–9.
- [19] 周志华. 机器学习 [M]. 清华大学出版社, 2016.

- [20] Han X, Xie W F, Fu Z. Nonlinear systems identification using dynamic multi-time scale neural networks [J]. Neurocomputing, 2011, 74 (17): 3428–3439.
- [21] Narendra K S, Kannan P. Identification and Control of Dynamical Systems Using Neural Networks [J]. IEEE Transactions on Neural Networks, 1990, 1 (1).
- [22] 朱娟萍, 侯忠生, 熊丹. 神经网络控制、无模型控制 PID 控制仿真比较 [J]. 系统仿真学报, 2005 (03): 751–754+766.
- [23] Korjani M M, Bazzaz O, Menhaj M B. Real time identification and control of dynamic systems using recurrent neural networks [J]. Artificial Intelligence Review, 2008, 30 (1-4): 1–17.
- [24] Huang G B, Zhu Q Y, Siew C K. Extreme learning machine: a new learning scheme of feedforward neural networks [J]. Proc.int.joint Conf.neural Netw, 2004 (2): 985–990.
- [25] Huang G B, Siew C K. Extreme learning machine: RBF network case [C]. In Proceedings of Control, Automation, Robotics and Vision Conference, 2004, 2005: 1029–1036.
- [26] Huang G B, Zhu Q Y, Siew C K. Extreme learning machine: Theory and applications [J]. Neurocomputing, 2006 (70): 489–501.
- [27] Huang G, Huang G B, Song S J, et al. Trends in extreme learning machines: A review [J]. Neural Networks the Official Journal of the International Neural Network Society, 2015, 61: 32–48.
- [28] Rong H, Zhao G. Direct adaptive neural control of nonlinear systems with extreme learning machine [J]. Neural Computation Application, 2013, 22: 577–586.
- [29] Liang N Y, B H G. A Fast and Accurate Online Sequential Learning Algorithm for Feedforward Networks [J]. IEEE Transactions on Neural Networks, 2006, 17 (6): 1411–1423.
- [30] 杨乐, 张瑞. 在线序列 ELM 算法及其发展 [J]. 西北大学学报 (自然科学版), 2012, 42 (6).
- [31] Shao Z F, Meng J E. An online sequential learning algorithm for regularized Extreme Learning Machine [J]. Neurocomputing.
- [32] 李军, 乃永强. 基于 ELM 的机器人自适应跟踪控制 [J]. 电机与控制学报, 2015, 19 (4): 106–116.
- [33] Wang N, Sun J C, Meng J E, et al. A Novel Extreme Learning Control Framework of Unmanned Surface Vehicles [J]. IEEE Transactions on Cybernetics, 2016, 46 (5): 1106–1117.
- [34] 郭雷. 关于反馈的作用及能力的认识 [J]. 自动化博览, 2003 (1): 5–7.
- [35] Guo 1997. On critical stability of discrete-time adaptive nonlinear control [J]. IEEE Transactions on Automatic Control, 1997, 42 (11): 1488–1499.
- [36] Xie L L, Guo L. How much uncertainty can be dealt with by feedback [J]. IEEE Transactions on Automatic Control, 2000, 45 (12): 2203–2217.
- [37] Guo L. Exploring the maximum capability of adaptive feedback [J]. INTERNATIONAL JOURNAL

- OF ADAPTIVE CONTROL AND SIGNAL PROCESSING, 2002, 16: 341–354.
- [38] Zhang Y X, Guo L. A Limit to the Capability of Feedback [J]. IEEE Transactions on Automatic Control, 2002, 47 (4): 687–692.
- [39] Ma H. Further results on limitations to the capability of feedback [J]. International Journal of Control, 2008, 81 (1): 21–42.
- [40] Ma H B. An “impossibility” theorem on a class of high-order discrete-time nonlinear control systems [J]. Systems Control Letters, 2008 (57): 497–504.
- [41] Escandell-Montero M, Soria-Olivas E, Magdalena-Benedito R. Regularized extreme learning machine for regression problems [J]. Neurocomputing, 2011, 74 (17): 3716–3721.
- [42] Huynh H, Won Y. Regularized online sequential learning algorithm for single-hidden layer feedforward neural networks [J]. Pattern Recognition Letters, 2011, 32 (14): 1930–1935.
- [43] 郑胤, 陈权崎, 章毓晋. 深度学习及其在目标和行为识别中的新进展 [J]. 中国图象图形学报, 2014 (02): 175–184.
- [44] Akusok A, Bjork K M, Miche Y. High-Performance Extreme Learning Machines: A Complete Toolbox for Big Data Applications [J]. Access IEEE, 2015 (3): 1011–1025.
- [45] Li X L, Jia C, Liu D X. Adaptive Control of Nonlinear Discrete-Time Systems by Using OS-ELM Neural Networks [J]. Abstract and Applied Analysis, 2014, 2014 (6088): 1–11.
- [46] Zhou H, Ma H, Li N, et al. Semi-parametric Adaptive Control of Discrete-time Systems Using Extreme Learning Machine [C]. In Proceedings of 9th International Conference on Modelling, Identification and Control, 2017.
- [47] 谭民, 王硕. 机器人技术研究进展 [J]. 自动化学报, 2013, 39 (7): 963–972.
- [48] Shin K G, D M N. A Dynamic Programming Approach to Trajectory Planning of Robotic Manipulators [J]. IEEE Transactions on Automatic Control, 1986, 31 (6): 491–500.
- [49] 刘金琨. 机器人运动控制系统的设计与 MATLAB 仿真 [M]. 清华大学出版社, 2008.
- [50] 吕俊磊. 关节型机器人多电机控制研究与仿真 [D]. 武汉: 武汉理工大学, 2013.
- [51] 刘松国. 六自由度串联机器人运动优化与轨迹跟踪控制研究 [D]. [S. l.]: 浙江大学, 2009.

附录 A ***

附录相关内容...

攻读学位期间发表论文与研究成果清单

- [1] HAO ZHOU, HONGBIN MA, NANNAN LI, CHENGUANG YANG. Semi-parametric Adaptive Control of Discrete-time Systems Using Extreme Learning Machine[C].The 9th International Conference on Modelling, Identification, Control, 2017. (EI 检索会议)
- [2] HAO ZHOU, HONGBIN MA*, HAIYANG ZHAN. Sampled Adaptive Control for Multi-joint Robotic Manipulator with Force Uncertainties[C]. Intelligent Robotics, Applications, 2016. (EI 检索会议)
- [3] HAO ZHOU, HONGBIN MA*, DONG WANG, SUNJIE CHEN. Stochastic Adaptive Control of Semi-flexible Robotic Manipulator[C], 2016. 2016 International conference on Advanced Robotics, Intelligent Systems, 2016. (EI 检索会议)
- [4] 王冬, 马宏宾, 周浩, 陈孙杰. 一种基于 iBeacon 的室内定位系统及方法 [P]. 2016. (发明专利, 已受理)
- [5] 王浩, 马宏宾, 周浩, 陈孙杰. 基于 Kinect 骨骼追踪和无标定视觉伺服的人机协作系统 [P]. 2016. (发明专利, 已受理)
- [6] 周浩, 马宏宾, 陈孙杰, 李楠楠. 一种半柔性机械臂系统的控制方法 [P]. 2017. (发明专利, 已受理)

致谢

本论文的工作是在导师 *** 教授的指导下独立完成的。两年半的时光匆匆划过，虽有苦有泪，但它始终是我这一生中一段重要的旅程。研究生阶段让我在更好的完善自己的同时，也丰富了我的知识，开阔了眼界。而如今，我能够顺利的完成我的毕业论文，也是因为一直有那些人陪伴在我的左右，在我错误时指导我，在我失意时陪伴我，在我受挫时鼓励我的那些人。感谢你们一路上的指引和教导，让我有了今天的成就！

首先，我要感谢敬爱的导师 *** 教授。

在此，我也要特别感谢我的父母及其他亲人，你们的支持和帮助，一直是我前进的动力，能够顺利完成硕士学位，也离不开你们在经济上的支持，感恩你们无私的爱！

最后，感谢本论文中所引用的参考文献的作者，你们的文章给了我无限的启迪和智慧，感谢本论文的评审老师和答辩委员会老师，同时也感谢自动化学院的所有任课老师们，感谢各位老师的不惜吝教。

作者简介

本人…。